


**SISTEM PEMANTAUAN KEPADATAN PENGUNJUNG BERBASIS
COMPUTER VISION MENGGUNAKAN MODEL YOLO DI
KAWASAN WISATA MALIOBORO**

SKRIPSI



***THE SUSTAINABLE DEVELOPMENT GOALS
Industry, Innovation and Infrastructure
Affordable and Clean Energy
Climate Action***

Disusun oleh:

**RADEN ARYO BISMO NUGROHO
22/494473/TK/54233**

**PROGRAM SARJANA PROGRAM STUDI TEKNOLOGI INFORMASI
DEPARTEMEN TEKNIK ELEKTRO DAN TEKNOLOGI INFORMASI
FAKULTAS TEKNIK UNIVERSITAS GADJAH MADA
YOGYAKARTA
2026**

HALAMAN PENGESAHAN

SISTEM PEMANTAUAN KEPADATAN PENGUNJUNG BERBASIS *COMPUTER VISION* MENGGUNAKAN MODEL YOLO DI KAWASAN WISATA MALIOBORO

SKRIPSI

Diajukan Sebagai Salah Satu Syarat untuk Memperoleh
Gelar Sarjana Teknik
pada Departemen Teknik Elektro dan Teknologi Informasi
Fakultas Teknik
Universitas Gadjah Mada

Disusun oleh:

RADEN ARYO BISMO NUGROHO
22/494473/TK/54233

Telah disetujui dan disahkan

Pada tanggal

Dosen Pembimbing I

Dosen Pembimbing II

Dr. Ir. Rudy Hartanto, M.T., IPM.
NIP 196403151990031003

Ir. Azkario Rizky Pratama, S.T., M.Eng., Ph.D., IPM.
NIP 111199102201607102

PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan di bawah ini :

Nama : Raden Aryo Bismo Nugroho
NIM : 22/494473/TK/54233
Tahun terdaftar : 2022
Program : Sarjana
Program Studi : Teknologi Informasi
Fakultas : Teknik Universitas Gadjah Mada

Menyatakan bahwa dalam dokumen ilmiah Skripsi ini tidak terdapat bagian dari karya ilmiah lain yang telah diajukan untuk memperoleh gelar akademik di suatu lembaga Pendidikan Tinggi, dan juga tidak terdapat karya atau pendapat yang pernah ditulis atau diterbitkan oleh orang/lembaga lain, kecuali yang secara tertulis disitasi dalam dokumen ini dan disebutkan sumbernya secara lengkap dalam daftar pustaka.

Dengan demikian saya menyatakan bahwa dokumen ilmiah ini bebas dari unsur-unsur plagiasi dan apabila dokumen ilmiah Skripsi ini di kemudian hari terbukti merupakan plagiasi dari hasil karya penulis lain dan/atau dengan sengaja mengajukan karya atau pendapat yang merupakan hasil karya penulis lain, maka penulis bersedia menerima sanksi akademik dan/atau sanksi hukum yang berlaku.

Yogyakarta, tanggal-bulan-tahun

Materai Rp10.000

(Tanda tangan)

Raden Aryo Bismo Nugroho
22/494473/TK/54233

HALAMAN PERSEMBAHAN

Tuliskan kepada siapa skripsi ini dipersembahkan!

contoh

KATA PENGANTAR

Contoh: Puji syukur ke hadirat Allah SWT atas limpahan rahmat, karunia, serta petunjuk-Nya sehingga tugas akhir berupa penyusunan skripsi ini telah terselesaikan dengan baik. Dalam hal penyusunan tugas akhir ini penulis telah banyak mendapatkan arahan, bantuan, serta dukungan dari berbagai pihak. Oleh karena itu pada kesempatan ini penulis mengucapkan terima kasih kepada:

1. Bapak Prof. Ir. Hanung Adi Nugroho, S.T., M.Eng., Ph.D., IPM., SMIEEE. selaku Ketua Departemen Teknik Elektro dan Teknologi Informasi Fakultas Teknik Universitas Gadjah Mada.
2. Bapak Dr. Iswandi, S.T., M.Eng./Dr. Ahmad Nasikun, S.T., M.Sc./Syukron Abu Ishaq Alfarozi, S.T., Ph.D. (**pilih yang sesuai**) selaku Ketua Program Studi Teknik Elektro/Teknologi Informasi/Teknik Biomedis (**pilih yang sesuai**).
3. Bapak selaku dosen pembimbing pertama
4. Ibu selaku dosen pembimbing kedua
5. <isi dengan nama orang lainnya>

Akhir kata penulis berharap semoga skripsi ini dapat memberikan manfaat bagi kita semua, aamiin.

Yogyakarta, <tanggal harus sebelum tanggal pendadaran>

Penulis

DAFTAR ISI

HALAMAN PENGESAHAN	ii
PERNYATAAN BEBAS PLAGIASI	iii
HALAMAN PERSEMBAHAN	iv
KATA PENGANTAR	v
DAFTAR ISI	vi
DAFTAR TABEL	ix
DAFTAR GAMBAR	x
DAFTAR SINGKATAN.....	xi
INTISARI.....	xiii
ABSTRACT	xiv
BAB I Pendahuluan	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan Penelitian.....	3
1.4 Batasan Penelitian	3
1.5 Manfaat Penelitian	4
1.6 Sistematika Penulisan.....	5
BAB II Tinjauan Pustaka dan Dasar Teori	6
2.1 Tinjauan Pustaka	6
2.2 Dasar Teori	7
2.2.1 Deteksi Objek	8
2.2.2 Arsitektur YOLO.....	8
2.2.3 Metrik Evaluasi Deteksi Objek.....	9
2.2.4 Ketidakseimbangan Kelas pada Deteksi Objek.....	10
2.2.5 Anotasi Semi-Otomatis	11
2.2.6 Tingkat Pelayanan Pejalan Kaki.....	11
2.3 Analisis Perbandingan Metode	12
2.3.1 Perbandingan Pendekatan Deteksi Objek	12
2.3.2 Pemilihan Varian YOLO untuk Penelitian	13
BAB III Metode Penelitian.....	15
3.1 Gambaran Umum Penelitian	15
3.2 Alat dan Bahan Tugas Akhir	15
3.2.1 Perangkat Keras	15
3.2.2 Perangkat Lunak	16
3.3 Pengumpulan Data.....	17
3.3.1 Sumber dan Mekanisme Pengambilan <i>Frame</i>	17

3.3.2	Penjadwalan dan Variasi Kondisi.....	18
3.4	Anotasi Data.....	18
3.4.1	Strategi Anotasi Semi-Otomatis	18
3.4.2	Perbandingan Pendekatan Pelabelan Otomatis	19
3.4.3	Anotasi Manual dan Koreksi	20
3.5	Pembersihan dan Pembagian Dataset	21
3.5.1	Pembagian <i>Train</i> , <i>Validation</i> , dan <i>Test</i>	21
3.5.2	Pembersihan Geometris Anotasi	21
3.5.3	Distribusi dan Ketidakseimbangan Kelas	22
3.6	Pelatihan dan Perbandingan Model	23
3.6.1	Konfigurasi Pelatihan	23
3.6.2	Prapemrosesan dan Augmentasi.....	24
3.6.3	Skema Pelatihan dan Perbandingan	24
3.7	Evaluasi Model.....	25
3.7.1	Metrik Evaluasi	25
3.7.2	Desain Evaluasi dan Pemilihan Model	25
3.8	Penyetelan Hyperparameter Model Terpilih	26
3.8.1	Dasar dan Strategi Penyetelan	26
3.8.2	Hasil Penyetelan dan Analisis	26
3.9	Perancangan dan Implementasi Sistem	28
3.9.1	Arsitektur Sistem.....	28
3.9.2	Penanganan Aliran CCTV dan Penjadwalan Inferensi	29
3.9.3	Estimasi Kepadatan dan Ambang Notifikasi.....	30
3.9.4	Visualisasi Kepadatan pada Dashboard	31
BAB IV	Hasil dan Pembahasan.....	33
4.1	Pembahasan Tujuan 1 dengan Hasil Penelitian 1 (Ubah Judul Sesuai dengan Hal yang Hendak dibahas)	33
4.2	Pembahasan Tujuan 1 dengan Hasil Penelitian 2 (Ubah Judul Sesuai dengan Hal yang Hendak dibahas)	33
4.3	Pembahasan Tujuan 2 dengan Hasil Penelitian 3 (Ubah Judul Sesuai dengan Hal yang Hendak dibahas)	33
4.4	Perbandingan Hasil Penelitian dengan Hasil Terdahulu	33
BAB V	Tambahan (Opsional)	34
BAB VI	Kesimpulan dan Saran.....	35
6.1	Kesimpulan.....	35
6.2	Saran.....	35
DAFTAR PUSTAKA		36
LAMPIRAN		L-1
L.1	Isi Lampiran.....	L-1

L.2	Panduan Latex.....	L-2
L.2.1	Syntax Dasar	L-2
L.2.1.1	Penggunaan Sitasi	L-2
L.2.1.2	Penulisan Gambar	L-2
L.2.1.3	Penulisan Tabel	L-2
L.2.1.4	Penulisan formula.....	L-2
L.2.1.5	Contoh list.....	L-3
L.2.2	Blok Beda Halaman.....	L-3
L.2.2.1	Membuat algoritma terpisah	L-3
L.2.2.2	Membuat tabel terpisah.....	L-3
L.2.2.3	Menulis formula terpisah halaman.....	L-4
L.3	Format Penulisan Referensi	L-6
L.3.1	Book	L-6
L.3.2	Handbook.....	L-8
L.4	Contoh Source Code	L-10
L.4.1	Sample algorithm	L-10
L.4.2	Sample Python code	L-11
L.4.3	Sample Matlab code	L-12

DAFTAR TABEL

Tabel 2.1	Perbandingan penelitian terdahulu.	7
Tabel 2.2	Perbandingan pendekatan deteksi objek terhadap kebutuhan sistem pemantauan.	13
Tabel 3.1	Versi perangkat lunak utama yang digunakan pada lingkungan pelatihan.	17
Tabel 3.2	Slot waktu pengambilan citra dalam satu hari.	18
Tabel 3.3	Jumlah <i>instance</i> hasil tiga kombinasi pelabelan otomatis pada 1.252 citra latih.	19
Tabel 3.4	Filter pembersihan kotak pembatas.	21
Tabel 3.5	Jumlah <i>instance</i> sebelum dan sesudah pembersihan pada tiap himpunan.	22
Tabel 3.6	Distribusi jumlah <i>instance</i> tiap kelas setelah pembersihan.	22
Tabel 3.7	Konfigurasi <i>hyperparameter</i> pelatihan.	24
Tabel 3.8	Perbandingan performa yolo11l pada resolusi 640 dan 960 (himpunan uji)	27
Tabel 3.9	Perbandingan F1 per kelas yolo11l pada resolusi 640 dan 960 (himpunan uji)	27
Tabel L.1	Tabel ini	L-2
Tabel L.2	Contoh tabel panjang.	L-4

DAFTAR GAMBAR

Gambar 3.1	Alur tahapan penelitian.	16
Gambar 3.2	Contoh kesalahan deteksi tiga bangku taman yang terdeteksi sebagai objek.	20
Gambar 3.3	Kamera CCTV yang sama pada dua sudut pandang berbeda	30
Gambar L.1	Contoh gambar.	L-2

DAFTAR SINGKATAN

[SAMPLE]

b	=	bias
$K(x_i, x_j)$	=	fungsi kernel
y	=	kelas keluaran
C	=	parameter untuk mengendalikan besarnya pertukaran antara penalti variabel slack dengan ukuran margin
L_D	=	persamaan Lagrange dual
L_P	=	persamaan Lagrange primal
$\mathbf{w}$	=	vektor bobot
$\mathbf{x}$	=	vektor masukan
ANFIS	=	Adaptive Network Fuzzy Inference System
ANSI	=	American National Standards Institute
DAG	=	Directed Acyclic Graph
DDAG	=	Decision Directed Acyclic Graph
HIS	=	Hue Saturation Intensity
QP	=	Quadratic Programming
RBF	=	Radial Basis Function
RGB	=	Red Green Blue
SV	=	Support Vector
SVM	=	Support Vector Machines

INTISARI

Intisari ditulis menggunakan bahasa Indonesia dengan jarak antar baris 1 spasi dan maksimal 1 halaman. Intisari sekurang-kurangnya berisi tentang latar belakang dan tujuan penelitian, metodologi yang digunakan, hasil penelitian, kesimpulan dan implikasi, dan Kata kunci yang berhubungan dengan penelitian.

Kata Kunci ditulis maksimal 5 kata yang paling berhubungan dengan isi skripsi. Silakan mengacu pada ACM / IEEE *Computing classification* jika Anda adalah mahasiswa Sarjana TI <http://www.acm.org/about/class/> atau mengacu kepada IEEE keywords http://www.ieee.org/documents/taxonomy_v101.pdf jika Anda berasal dari Prodi Sarjana TE.

Kata kunci : Kata kunci 1, Kata kunci 2, Kata kunci 3, Kata kunci 4, Kata kunci 5

Contoh Abstrak Teknik Elektro:

"Penelitian ini bertujuan untuk mengembangkan sistem pengendalian suhu ruangan dengan menggunakan microcontroller. Metodologi yang digunakan adalah desain sirkuit, implementasi sistem pengendalian, dan pengujian performa. Hasil penelitian menunjukkan bahwa sistem pengendalian suhu ruangan yang dikembangkan mampu mengendalikan suhu ruangan dengan akurasi sebesar $\pm 0,5^{\circ}\text{C}$. Kesimpulan dari penelitian ini adalah sistem pengendalian suhu ruangan yang dikembangkan efektif dan efisien.

Kata kunci: microcontroller, sistem pengendalian suhu, akurasi."

Contoh Abstrak Teknik Biomedis:

"Penelitian ini bertujuan untuk mengevaluasi keefektifan prototipe alat pemantau denyut jantung berbasis elektrokardiogram (ECG) untuk pasien jantung. Metodologi yang digunakan meliputi desain dan pembuatan prototipe, pengujian dengan pasien, dan analisis data. Hasil penelitian menunjukkan bahwa prototipe alat pemantau denyut jantung berbasis ECG memiliki akurasi yang baik dan mampu memantau denyut jantung pasien secara efektif. Kesimpulan dari penelitian ini adalah prototipe alat pemantau denyut jantung berbasis ECG merupakan solusi yang efektif dan efisien untuk memantau pasien jantung.

Kata kunci: elektrokardiogram, alat pemantau denyut jantung, akurasi."

Contoh Abstrak Teknologi Informasi:

"Penelitian ini bertujuan untuk mengevaluasi keamanan dan privasi pengguna aplikasi media sosial terpopuler. Metodologi yang digunakan meliputi analisis kebijakan privasi dan pengaturan keamanan, pengujian penetrasi, dan survei pengguna. Hasil penelitian menunjukkan bahwa beberapa aplikasi media sosial memiliki kebijakan privasi yang kurang jelas dan rendahnya tingkat keamanan. Kesimpulan dari penelitian ini adalah pentingnya meningkatkan kebijakan privasi dan tingkat keamanan pada aplikasi media sosial untuk melindungi privasi dan data pengguna.

Kata kunci: media sosial, keamanan, privasi, pengguna."

ABSTRACT

Abstract ditulis italic (miring) menggunakan bahasa Inggris dengan jarak antar baris 1 spasi dan maksimal 1 halaman. Abstract adalah versi Bahasa Inggris dari intisari. Abstract dapat ditulis dalam beberapa paragraf. Baris pertama paragraph harus menjorok ke dalam sekitar 1 cm. Tidak disarankan menggunakan mesin penerjemah melainkan tulis ulang.

Keywords : Keyword 1, Keyword 2, Keyword 3, Keyword 4, Keyword 5

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kawasan Malioboro adalah pusat pariwisata Kota Yogyakarta yang menampung pergerakan pengunjung dalam jumlah besar setiap hari. Koridor pejalan kaki sepanjang sekitar 1,3 km menghubungkan Titik Nol Yogyakarta, Benteng Vredenburg, Pasar Beringharjo, hingga Stasiun Tugu, dan menjadi ruang publik utama bagi wisatawan maupun warga lokal [1]. Data Pemerintah Kota Yogyakarta mencatat kunjungan ke Malioboro sepanjang tahun 2024 berkisar antara 118.255 pengunjung pada bulan Maret hingga 604.240 pengunjung pada bulan Mei, dengan akumulasi sekitar 4,7 juta pengunjung dalam satu tahun [2]. Pada skala kota, perjalanan wisatawan nusantara ke Kota Yogyakarta sepanjang tahun 2025 berkisar antara 629.936 hingga 1.034.536 perjalanan per bulan [3]. Konsentrasi pengunjung memuncak pada periode tertentu. Saat arus mudik lebaran, volume pejalan kaki di Malioboro meningkat hampir dua kali lipat dibandingkan hari biasa, dengan puncak pada hari kedua dan ketiga lebaran [4].

Kepadatan setinggi itu menimbulkan tekanan pada ruang dan lalu lintas kawasan. Sebagai pusat bisnis sekaligus destinasi wisata, Malioboro kerap mengalami kemacetan akibat lonjakan penggunaan kendaraan [5]. Pengelolaan lalu lintas di kawasan ini bertumpu pada pengaturan administratif yang mengacu pada Peraturan Daerah Kota Yogyakarta Nomor 1 Tahun 2019 serta pengawasan langsung oleh petugas [5]. Pemantauan kondisi kepadatan umumnya dilakukan secara manual melalui kamera pengawas yang diamati operator. Pendekatan ini memiliki keterbatasan yang melekat, yaitu cakupan pengamatan yang terbatas, kebutuhan daya yang tinggi, dan ketergantungan pada pengawasan operator secara terus-menerus [6]. Akibatnya, informasi kepadatan yang objektif dan tersedia secara langsung untuk banyak titik sekaligus sulit diperoleh.

Sejumlah kota di dunia telah beralih ke sistem pemantauan berbasis kecerdasan buatan untuk mengatasi keterbatasan tersebut. Kota Hangzhou di Tiongkok mengoperasikan sistem *City Brain* sejak tahun 2016, yang memproses data waktu nyata dari kamera dan sensor pada lampu lalu lintas untuk mengoptimalkan arus kendaraan [7]. Sistem tersebut dilaporkan meningkatkan kecepatan rata-rata lalu lintas sebesar 15,3 persen dan menurunkan kemacetan pada jam sibuk sebesar 9,2 persen [7]. Pada tingkat teknis, *computer vision* berbasis kamera pengawas telah terbukti mampu memantau kerumunan secara otomatis. Penelitian di sebuah pusat perbelanjaan di Indonesia, misalnya, menggunakan metode YOLOv3-Tiny untuk mendeteksi kerumunan dari rekaman kamera dan memicu peringatan ketika jumlah orang melampaui ambang tertentu [8]. Penggunaan *computer vision* memungkinkan pengurangan ketergantungan

pada pengawasan manusia sekaligus memperluas cakupan pemantauan [6].

Penerapan *computer vision* di kawasan seperti Malioboro menghadapi kendala yang khas. Model deteksi objek pada umumnya dilatih menggunakan dataset publik berskala besar seperti COCO yang tidak memuat kendaraan khas Indonesia terutama di Malioboro, seperti andong, becak, dan bajaj. Model yang dilatih pada dataset semacam COCO maupun UA-DETRAC terbukti kesulitan menggeneralisasi pada kondisi lalu lintas yang padat, heterogen, dan tidak teratur di kota-kota berkembang [9]. Padahal, Malioboro memuat objek yang beragam, mulai dari pejalan kaki, kendaraan bermotor umum, hingga moda transportasi tradisional seperti andong dan becak. Kondisi ini menuntut dataset dan model deteksi yang dirancang khusus untuk karakteristik objek lokal yang bukan sekadar mengandalkan model siap pakai.

Penelitian ini membangun sistem pemantauan kepadatan pengunjung di kawasan Malioboro menggunakan pendekatan *computer vision* dengan model YOLO. Dataset deteksi untuk sembilan kelas objek, yaitu andong, bajaj, becak, sepeda, bus, mobil, motor, orang, dan truk, dibangun dari rekaman kamera pengawas kawasan Malioboro. Beberapa varian model YOLOv8 dan YOLO11 dilatih dan dibandingkan untuk menentukan model dengan performa deteksi terbaik. Model terpilih kemudian diimplementasikan ke dalam sistem berbasis web yang memproses aliran video kamera pengawas secara waktu nyata dan menampilkan jumlah objek pada tiap kategori. Sebagai dasar penetapan ambang notifikasi kepadatan, sistem mengacu pada konsep tingkat pelayanan pejalan kaki (*level of service*) yang diadopsi dalam Peraturan Menteri PUPR Nomor 03/PRT/M/2014 [10, 11]. Berdasarkan uraian tersebut, beberapa permasalahan dirumuskan pada subbab berikut.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, yaitu kebutuhan pemantauan kepadatan otomatis di kawasan Malioboro yang masih dikelola secara manual, permasalahan dalam penelitian ini dirumuskan sebagai berikut.

1. Dataset deteksi objek untuk sembilan kelas khas kawasan Malioboro, yaitu andong, bajaj, becak, sepeda, bus, mobil, motor, orang, dan truk, belum tersedia karena sebagian kelas tersebut tidak terdapat pada dataset publik berskala besar seperti COCO.
2. Varian model YOLOv8 dan YOLO11 yang memberikan performa deteksi terbaik untuk kesembilan kelas tersebut belum diketahui, termasuk pengaruh ketidakseimbangan jumlah *instance* antar kelas terhadap performa deteksi pada tiap kelas.
3. Model deteksi terbaik belum diimplementasikan ke dalam sistem pemantauan kepadatan berbasis web yang memproses aliran video kamera pengawas secara

waktu nyata.

1.3 Tujuan Penelitian

Tujuan penelitian ini dirumuskan untuk menjawab setiap permasalahan yang telah dipaparkan, dengan keterkaitan satu-satu antara tiap tujuan dan tiap rumusan masalah. Ketiga tujuan tersusun mengikuti alur penelitian, mulai dari pembentukan dataset sebagai fondasi, dilanjutkan pemilihan dan optimasi model deteksi melalui perbandingan dan penyetelan, hingga penerapan model terpilih ke dalam sistem yang berfungsi.

1. Membangun dataset deteksi sembilan kelas objek kawasan Malioboro (andong, bajaj, becak, sepeda, bus, mobil, motor, orang, dan truk) dari rekaman kamera pengawas melalui anotasi semi-otomatis berbantuan model *pretrained* dengan koreksi manual.
2. Membandingkan performa varian model YOLOv8 dan YOLO11 dalam mendeteksi kesembilan kelas menggunakan metrik mAP50, mAP50-95, dan F1, menganalisis pengaruh ketidakseimbangan kelas terhadap performa deteksi tiap kelas, lalu memilih model terbaik dan mengoptimasi performanya melalui penyetelan *hyperparameter*.
3. Mengimplementasikan model deteksi terbaik ke dalam sistem pemantauan kepadatan berbasis web yang memproses aliran video kamera pengawas secara waktu nyata dan mengukur performa inferensinya.

1.4 Batasan Penelitian

Penelitian ini diberi batasan agar lingkupnya tetap terarah dan dapat diselesaikan dengan sumber daya yang tersedia. Batasan mencakup lokasi dan sumber data, kelas objek yang dideteksi, varian model yang dibandingkan, serta fungsi sistem yang dikembangkan. Penetapan batasan ini sekaligus menjaga agar perbandingan model dilakukan pada kondisi yang terkontrol. Ruang lingkup selengkapnya diuraikan sebagai berikut.

1. Lokasi penelitian dibatasi pada kawasan wisata Malioboro, Kota Yogyakarta, dengan sumber data berupa aliran video dari 22 titik kamera pengawas (*closed-circuit television*, CCTV) publik di kawasan tersebut.
2. Objek yang dideteksi dibatasi pada sembilan kelas, yaitu andong, bajaj, becak, sepeda, bus, mobil, motor, orang, dan truk.
3. Model deteksi yang dilatih dan dibandingkan dibatasi pada varian YOLOv8 dan YOLO11.
4. Dataset yang digunakan adalah data primer yang dibangun dari rekaman kamera pengawas kawasan Malioboro melalui anotasi semi-otomatis dengan koreksi manual. Rincian proses anotasi dijelaskan pada Bab III.
5. Sistem hanya melakukan pemantauan (*monitoring*) kepadatan secara waktu nyata

dan tidak melakukan prediksi kepadatan pada waktu mendatang.

6. Penghitungan objek dilakukan per *frame*. Sistem tidak melakukan pelacakan (*tracking*) objek antar-*frame*.
7. Penetapan ambang notifikasi berbasis tingkat pelayanan (*level of service*) untuk kepadatan orang hanya diterapkan pada dua titik kamera yang dikalibrasi sebagai contoh. Titik kamera lainnya serta penetapan ambang untuk kemacetan kendaraan berada di luar lingkup dan menjadi arah pengembangan lanjutan.
8. Penelitian berfokus pada perbandingan model deteksi dan implementasi fungsional sistem. Perancangan berbasis *User-Centered Design* (UCD) dan pengujian *usability* tidak termasuk dalam lingkup penelitian.

1.5 Manfaat Penelitian

Hasil penelitian ini diharapkan bermanfaat pada dua sisi yang saling melengkapi, yaitu pengembangan keilmuan dan penerapan di lapangan. Sisi akademis berkaitan dengan ketersediaan data dan temuan yang dapat dijadikan rujukan penelitian berikutnya, sedangkan sisi praktis berkaitan dengan kegunaan sistem bagi pengelola kawasan Malioboro. Uraian masing-masing manfaat adalah sebagai berikut.

Manfaat akademis:

1. Penelitian ini menghasilkan dataset deteksi objek untuk sembilan kelas khas kawasan Malioboro, termasuk andong, becak, dan bajaj yang tidak terdapat pada dataset publik seperti COCO, sehingga dapat menjadi sumber data bagi penelitian deteksi objek lokal selanjutnya.
2. Hasil perbandingan performa varian model YOLOv8 dan YOLO11 pada dataset objek lokal dengan distribusi kelas yang bervariasi dapat menjadi rujukan dalam pemilihan model deteksi objek untuk kasus serupa.

Manfaat praktis:

1. Sistem pemantauan yang dibangun dapat membantu pengelola kawasan Malioboro memperoleh informasi kepadatan pengunjung secara waktu nyata sebagai dasar pengambilan keputusan pengendalian kerumunan.
2. Pemantauan berbasis *computer vision* memberikan informasi kepadatan yang lebih objektif dan mencakup lebih banyak titik dibandingkan pengamatan manual oleh operator.

1.6 Sistematika Penulisan

Bab I berisi pendahuluan yang menjelaskan dasar dilakukannya penelitian. Bagian latar belakang memaparkan kondisi kepadatan pengunjung di kawasan Malioboro dan keterbatasan pemantauan manual yang berjalan saat ini, yang menjadi alasan dibangunnya sistem pemantauan otomatis. Dari latar belakang tersebut diturunkan rumusan masalah, tujuan, batasan, dan manfaat penelitian. Bab ini ditutup dengan sistematika penulisan yang menggambarkan susunan keseluruhan naskah.

Bab II menyajikan tinjauan pustaka dan dasar teori yang melandasi penelitian. Tinjauan pustaka membahas penelitian terdahulu yang relevan beserta posisi penelitian ini di antaranya. Dasar teori menguraikan konsep deteksi objek, arsitektur model YOLOv8 dan YOLO11, metrik evaluasi deteksi, ketidakseimbangan kelas, anotasi semi-otomatis, dan tingkat pelayanan (*level of service*) pejalan kaki. Bab ini ditutup dengan analisis perbandingan metode yang menjadi dasar pemilihan model deteksi.

Bab III menguraikan metode penelitian secara bertahap. Pembahasan dimulai dari pengumpulan data berupa aliran kamera pengawas, dilanjutkan anotasi semi-otomatis dengan koreksi manual dan prapemrosesan data untuk membentuk dataset. Bagian berikutnya menjelaskan konfigurasi pelatihan model serta metode evaluasi yang digunakan untuk membandingkan varian model, serta penyetelan *hyperparameter* pada model terpilih untuk mengoptimasi performanya. Bab ini juga memuat perancangan dan implementasi sistem pemantauan berbasis web yang memproses video secara waktu nyata.

Bab IV menyajikan hasil penelitian beserta pembahasannya. Bagian awal memaparkan hasil pembentukan dataset, dilanjutkan hasil pelatihan dan perbandingan varian model YOLOv8 dan YOLO11 berdasarkan metrik yang telah ditetapkan. Analisis performa pada tiap kelas dibahas untuk melihat pengaruh ketidakseimbangan kelas terhadap hasil deteksi. Bagian selanjutnya menyajikan hasil penyetelan *hyperparameter* pada model terpilih beserta dampaknya terhadap akurasi dan kecepatan inferensi. Bagian akhir memaparkan hasil implementasi dan pengujian sistem pemantauan.

Bab V berisi kesimpulan dan saran. Kesimpulan menjawab setiap rumusan masalah berdasarkan temuan yang diperoleh pada Bab IV. Saran memuat arah pengembangan yang dapat dilakukan pada penelitian selanjutnya sesuai dengan lingkup penelitian ini.

BAB II

TINJAUAN PUSTAKA DAN DASAR TEORI

2.1 Tinjauan Pustaka

Pemantauan kerumunan berbasis deteksi objek menggunakan model YOLO telah menjadi topik penelitian yang aktif dalam beberapa tahun terakhir. Sebagian penelitian berfokus pada penghitungan jumlah orang secara waktu nyata dari rekaman kamera. Gündüz dan Işık [12] mengusulkan metode deteksi kerumunan waktu nyata yang menentukan batas suatu wilayah pada video, menghitung jumlah orang di dalamnya, dan membandingkan performa beberapa varian model YOLO untuk keperluan tersebut. Pendekatan dengan tujuan serupa diterapkan Ginting dkk. [8] yang menggabungkan YOLOv3-Tiny dan algoritma Viola-Jones untuk mendeteksi kerumunan di pusat perbelanjaan serta memicu peringatan ketika jumlah orang melampaui ambang tertentu. Pada penerapan di perangkat dengan sumber daya terbatas, Hansika dkk. [13] membangun kerangka penghitungan kerumunan ringan menggunakan YOLOv8n dan algoritma pelacakan Norfair yang dijalankan pada perangkat tepi Raspberry Pi 5, dengan hasil ditampilkan melalui *dashboard*.

Sebagian penelitian lain menekankan keterpaduan deteksi dengan antarmuka pemantauan dan sistem peringatan. Apeksha dkk. [14] mengembangkan platform AI-Transit Alerts yang menghitung jumlah penumpang transportasi umum secara waktu nyata menggunakan YOLOv8, menampilkannya pada *dashboard* interaktif, dan mengirim peringatan otomatis ketika jumlah penumpang melampaui batas aman. Wong dan Law [15] menyoroti keterbatasan pemantauan CCTV manual yang melelahkan dan rawan kesalahan pada ruang publik padat, lalu mengusulkan kerangka yang menggabungkan rekaman CCTV dengan informasi denah ruang untuk memetakan lintasan individu dan memantau kepadatan secara waktu nyata.

Di luar deteksi orang, model YOLO juga digunakan untuk deteksi kendaraan dalam pemantauan lalu lintas. Zhang dkk. [16] mengembangkan model YOLOv5 yang ditingkatkan untuk deteksi kendaraan waktu nyata dengan fokus menurunkan tingkat deteksi keliru (*false detection*). Ringkasan perbandingan penelitian terdahulu disajikan pada Tabel 2.1.

Penelitian-penelitian tersebut menunjukkan model YOLO efektif untuk pemantauan kerumunan maupun kendaraan secara waktu nyata. Meskipun demikian, sebagian besar berfokus pada satu jenis objek saja, yaitu orang atau kendaraan, dan mengandalkan kelas objek yang tersedia pada dataset umum. Belum ada penelitian yang menangani kombinasi objek khas kawasan wisata Indonesia, termasuk andong, becak, dan bajaj, dalam satu sistem. Perbandingan antar varian model pada sebagian

Tabel 2.1. Perbandingan penelitian terdahulu.

Penelitian	Model	Domain Aplikasi	Catatan
Gündüz & Işık [12]	Beberapa varian YOLO	Penghitungan kerumunan dalam ruang	Membandingkan varian YOLO dan menentukan wilayah hitung
Ginting dkk. [8]	YOLOv3-Tiny, Viola-Jones	Deteksi kerumunan di pusat perbelanjaan	Memicu peringatan saat ambang terlampaui
Hansika dkk. [13]	YOLOv8n, Norfair	Penghitungan kerumunan pada perangkat tepi	Ringan, hemat sumber daya, dengan <i>dashboard</i>
Apeksha dkk. [14]	YOLOv8	Penghitungan penumpang transportasi umum	<i>Dashboard</i> interaktif dan peringatan otomatis
Wong & Law [15]	Model <i>deep learning</i>	Pemantauan kepadatan ruang publik	Menggabungkan CCTV dengan denah ruang
Zhang dkk. [16]	YOLOv5 (ditingkatkan)	Deteksi kendaraan lalu lintas	Menurunkan tingkat deteksi keliru
Penelitian ini	YOLOv8 & YOLO11 (n, s, m, l)	Deteksi sembilan kelas objek di Malioboro	Multi-kelas mencakup andong, becak, dan bajaj. Membandingkan dua generasi dan diimplementasikan sebagai sistem berbasis web

besar penelitian juga terbatas pada satu generasi YOLO. Penelitian ini menempatkan diri pada celah tersebut dengan membandingkan varian YOLOv8 dan YOLO11 untuk mendeteksi sembilan kelas objek khas kawasan Malioboro secara bersamaan, kemudian mengimplementasikan model terbaik ke dalam sistem pemantauan berbasis web.

2.2 Dasar Teori

Subbab ini menyusun landasan teori mengikuti alur kerja sistem yang dibangun, mulai dari teori deteksi objek hingga penerjemahan hasil deteksi menjadi penilaian kepadatan. Teori deteksi objek dan arsitektur YOLO menjelaskan cara objek dikenali dari citra kamera pengawas, sedangkan metrik evaluasi menetapkan ukuran kualitas deteksi yang dihasilkan. Ketidakeimbangan kelas dan anotasi semi-otomatis membahas dua

persoalan data yang menentukan keberhasilan pelatihan model pada konteks kawasan Malioboro. Bagian terakhir, yaitu tingkat pelayanan pejalan kaki, menghubungkan keluaran model dengan tujuan akhir sistem berupa estimasi kepadatan dan penetapan ambang notifikasi.

2.2.1 Deteksi Objek

Deteksi objek adalah tugas *computer vision* yang bertujuan mengidentifikasi lokasi dan kategori setiap objek yang ada dalam suatu gambar secara bersamaan [17]. Keluaran dari sistem deteksi objek berupa kotak pembatas (*bounding box*) yang melingkupi setiap objek beserta label kelas dan nilai keyakinan (*confidence score*) yang menyertainya.

Pendekatan deteksi objek berbasis *deep learning* secara umum dibagi menjadi dua kategori, yaitu *two-stage detector* dan *one-stage detector*. *Two-stage detector* bekerja dalam dua tahap terpisah: tahap pertama menghasilkan kandidat wilayah yang mungkin mengandung objek, dan tahap kedua mengklasifikasikan serta menyempurnakan posisi kotak pembatas pada setiap kandidat wilayah tersebut. Faster R-CNN [18] adalah salah satu arsitektur *two-stage* yang berpengaruh, yang memperkenalkan *Region Proposal Network* (RPN) untuk menghasilkan proposal wilayah secara efisien dengan berbagi fitur konvolusional antara tahap proposal dan tahap deteksi. Pendekatan ini menghasilkan akurasi yang tinggi, namun kecepatan inferensinya terbatas karena sifat dua tahapnya, yaitu sekitar 5 *frame* per detik pada GPU.

One-stage detector menggabungkan kedua tahap tersebut menjadi satu jaringan tunggal yang langsung memprediksi kotak pembatas dan label kelas dari seluruh gambar dalam satu kali evaluasi [19]. Pendekatan ini jauh lebih cepat dibandingkan *two-stage detector* dan lebih sesuai untuk kebutuhan deteksi waktu nyata, meskipun pada generasi awal memiliki akurasi yang sedikit lebih rendah. Penelitian ini menggunakan pendekatan *one-stage* karena kebutuhan pemantauan kepadatan secara waktu nyata dari aliran video kamera pengawas.

Komponen penting dalam arsitektur detektor modern adalah *Feature Pyramid Network* (FPN) [20]. FPN membangun representasi piramida fitur multi-skala dari jaringan konvolusional dengan biaya komputasi yang minimal, menggunakan arsitektur *top-down* dengan koneksi lateral untuk menghasilkan peta fitur berkualitas tinggi di semua skala. Kemampuan mendeteksi objek dalam berbagai ukuran ini menjadikan FPN komponen penting dalam detektor YOLO generasi terbaru, termasuk YOLOv8 dan YOLO11 yang digunakan dalam penelitian ini.

2.2.2 Arsitektur YOLO

YOLO (*You Only Look Once*) diperkenalkan oleh Redmon dkk. [19] sebagai pendekatan deteksi objek *one-stage* yang memformulasikan deteksi sebagai masalah

regresi tunggal dari piksel gambar ke koordinat kotak pembatas dan probabilitas kelas. Model dasar YOLO mampu memproses gambar pada kecepatan 45 *frame* per detik, sedangkan versi yang lebih ringan mencapai 155 *frame* per detik. Sejak diperkenalkan, arsitektur YOLO telah berkembang melalui banyak iterasi yang membawa peningkatan pada akurasi, efisiensi komputasi, dan kemampuan multitugas [21].

YOLOv8 dirilis oleh Ultralytics pada Januari 2023 dan tersedia dalam lima ukuran, yaitu nano (n), small (s), medium (m), large (l), dan extra-large (x) [21]. Arsitektur YOLOv8 memperkenalkan modul C2f (*cross-stage partial bottleneck with two convolutions*) pada *backbone* sebagai pengganti modul C3 pada versi sebelumnya. C2f menggabungkan fitur tingkat tinggi dengan informasi kontekstual untuk meningkatkan akurasi deteksi. YOLOv8 juga menggunakan model *anchor-free* dengan *decoupled head* yang memproses tugas klasifikasi dan regresi kotak pembatas secara terpisah, sehingga mengurangi konflik antar-tugas dan meningkatkan konvergensi pelatihan.

YOLO11 dirilis oleh Ultralytics pada September 2024 sebagai penerus YOLOv8 [22]. Khanam dan Hussain menganalisis inovasi arsitektur YOLO11, yang mencakup blok C3k2 (*Cross Stage Partial with kernel size 2*), komponen SPPF (*Spatial Pyramid Pooling Fast*), dan modul C2PSA (*Convolutional block with Parallel Spatial Attention*). Blok C3k2 meningkatkan ekstraksi fitur dengan kernel berukuran lebih kecil yang lebih efisien secara komputasi, sedangkan C2PSA menambahkan mekanisme perhatian spasial paralel untuk memperkuat kemampuan model menangkap konteks global dalam gambar. YOLO11 tersedia dalam skala nano hingga extra-large dan mendukung berbagai tugas *computer vision* termasuk deteksi objek, segmentasi, dan estimasi pose.

Kedua model tersebut, yaitu YOLOv8 dan YOLO11, dipilih dalam penelitian ini karena keduanya merupakan model resmi Ultralytics yang berbagi kerangka pelatihan, format data, dan antarmuka pemrograman yang identik. Keseragaman ini memungkinkan perbandingan yang terkontrol, di mana perbedaan performa dapat diatribusikan pada perbedaan arsitektur dan bukan pada perbedaan implementasi. Selain itu, kedua model memiliki skalabilitas yang baik untuk perangkat dengan sumber daya terbatas, yang relevan untuk kebutuhan inferensi waktu nyata pada sistem pemantauan [21].

Model transformer seperti RT-DETR [23] merupakan alternatif yang kompetitif dari segi akurasi, namun YOLOv8 dan YOLO11 dipilih karena efisiensi parameter, ekosistem yang matang, serta kemampuan deployment yang lebih luas pada berbagai jenis perangkat mulai dari server hingga perangkat tepi.

2.2.3 Metrik Evaluasi Deteksi Objek

Evaluasi performa model deteksi objek menggunakan sejumlah metrik standar yang saling melengkapi [24]. Metrik-metrik ini digunakan secara konsisten pada seluruh eksperimen dalam penelitian ini.

Intersection over Union (IoU) mengukur seberapa besar tumpang tindih antara kotak pembatas hasil prediksi dan kotak pembatas acuan (*ground truth*). IoU dihitung sebagai rasio luas irisan terhadap luas gabungan kedua kotak. Sebuah prediksi dinyatakan benar (*true positive*) jika nilai IoU-nya melampaui ambang tertentu.

Precision mengukur proporsi prediksi positif yang benar dari seluruh prediksi yang dihasilkan model, sedangkan *recall* mengukur proporsi objek yang berhasil dideteksi dari seluruh objek yang sebenarnya ada. Kedua metrik ini dihitung per kelas.

Average Precision (AP) merangkum kinerja detektor dengan menghitung luas area di bawah kurva *precision-recall* [24]. AP dihitung secara terpisah untuk setiap kelas objek. *mean Average Precision* (mAP) adalah rata-rata AP di seluruh kelas yang dievaluasi.

Dataset COCO [25] memperkenalkan dua varian mAP yang digunakan secara luas sebagai standar evaluasi. mAP50 dihitung pada ambang IoU 0,50, sementara mAP50-95 merupakan rata-rata mAP pada ambang IoU dari 0,50 hingga 0,95 dengan langkah 0,05. mAP50-95 memberikan evaluasi yang lebih ketat karena memperhitungkan ketepatan lokalisasi kotak pembatas pada berbagai tingkat kesesuaian. Dataset COCO sendiri memuat anotasi 91 jenis objek pada 328 ribu gambar dengan total 2,5 juta *instance* berlabel, dan telah menjadi tolok ukur standar untuk evaluasi detektor objek.

F1-score adalah rata-rata harmonik dari *precision* dan *recall*, memberikan metrik tunggal yang menyeimbangkan kedua aspek tersebut. F1 sangat berguna untuk mengevaluasi kinerja per kelas pada kondisi ketidakseimbangan kelas, karena memberikan penalti yang setara terhadap *precision* maupun *recall* yang rendah.

Dalam penelitian ini, metrik utama yang digunakan adalah mAP50, mAP50-95, *F1-score* per kelas, dan *confusion matrix* untuk menganalisis pola kesalahan deteksi.

2.2.4 Ketidakseimbangan Kelas pada Deteksi Objek

Ketidakseimbangan kelas adalah kondisi ketika jumlah *instance* antar kelas dalam dataset berbeda jauh. Oksuz dkk. [17] mengidentifikasi ketidakseimbangan kelas sebagai salah satu masalah utama dalam deteksi objek, yang dapat menyebabkan model lebih condong mempelajari kelas dengan jumlah *instance* besar dan mengabaikan kelas dengan jumlah *instance* kecil. Dampaknya terlihat pada *Average Precision* yang rendah untuk kelas minoritas meskipun mAP keseluruhan tampak cukup baik.

Dataset yang dibangun dalam penelitian ini menunjukkan ketidakseimbangan kelas yang ekstrem. Kelas orang memiliki 10.694 *instance* pada data latih, sedangkan kelas truk hanya memiliki 45 *instance*, dengan rasio sebesar 237:1. Kelas bajaj dan bus masing-masing hanya memiliki 96 dan 92 *instance*. Kondisi ini merupakan konsekuensi langsung dari komposisi objek yang ada di kawasan Malioboro, bukan kesalahan pengumpulan data.

Ketidakseimbangan ini diperkirakan berpengaruh pada performa per kelas model yang dilatih, khususnya pada kelas dengan *instance* sedikit seperti truk, bajaj, dan sepeda. Analisis pengaruh ketidakseimbangan ini terhadap F1-score per kelas disajikan pada BAB IV.

2.2.5 Anotasi Semi-Otomatis

Anotasi dataset dalam jumlah besar secara manual membutuhkan waktu dan sumber daya yang besar. Pendekatan anotasi semi-otomatis menggabungkan prediksi model *pretrained* dengan verifikasi dan koreksi manual untuk mempercepat proses anotasi tanpa mengorbankan kualitas secara keseluruhan [26]. Tenckhoff dkk. menunjukkan bahwa platform anotasi berbasis umpan balik model, di mana model *pretrained* menghasilkan anotasi awal yang kemudian diverifikasi dan diperbaiki oleh anotator manusia, menghasilkan penghematan waktu dan jumlah interaksi anotasi yang terukur dibandingkan anotasi penuh secara manual.

Dalam penelitian ini, pendekatan ini diterapkan pada 1.252 gambar yang dianotasi menggunakan model *pretrained* untuk enam kelas yang tersedia pada dataset umum, diikuti dengan verifikasi dan koreksi manual. Kelas yang tidak tersedia pada model *pretrained*, yaitu andong dan becak, dianotasi secara penuh manual. Himpunan validasi dan pengujian sebanyak 329 gambar dianotasi secara penuh manual untuk memastikan integritas evaluasi. Rincian pipeline anotasi diuraikan pada BAB III.

2.2.6 Tingkat Pelayanan Pejalan Kaki

Tingkat pelayanan (*level of service*, LOS) pejalan kaki adalah konsep kuantitatif yang mengklasifikasikan kondisi pergerakan pejalan kaki berdasarkan kepadatan dan kenyamanan. Fruin [10] mendefinisikan enam tingkat pelayanan (A hingga F) berdasarkan studi fotografi *time-lapse* terhadap pergerakan pejalan kaki, dengan parameter utama berupa kepadatan orang per meter persegi dan ruang yang tersedia per pejalan kaki. Tingkat A menggambarkan kondisi pergerakan bebas tanpa konflik antar-pejalan kaki, sedangkan tingkat E dan F menggambarkan kondisi padat di mana kontak fisik tidak terhindarkan dan pergerakan mandiri menjadi terbatas.

Di Indonesia, konsep LOS ini diadopsi dalam Peraturan Menteri PUPR Nomor 03/PRT/M/2014 tentang Pedoman Perencanaan, Penyediaan, dan Pemanfaatan Prasarana dan Sarana Jaringan Pejalan Kaki di Kawasan Perkotaan [11], yang menjadi acuan standar nasional untuk perencanaan jalur pedestrian. Penerapan standar nasional ini memberikan dasar ilmiah yang terukur untuk penetapan ambang notifikasi kepadatan pada sistem pemantauan yang dibangun dalam penelitian ini, khususnya untuk kelas orang pada kamera yang dikalibrasi.

Untuk menghitung kepadatan dari hasil deteksi, diperlukan pemetaan antara

koordinat piksel dan koordinat nyata di bidang tanah. Pemetaan ini dilakukan melalui estimasi homografi planar, yaitu transformasi perspektif yang mengubah titik-titik pada bidang gambar menjadi koordinat metrik di bidang tanah menggunakan korespondensi titik acuan yang diketahui dimensinya [10]. Dengan homografi yang telah dikalibrasi, jumlah objek yang terdeteksi dalam suatu zona dapat dibagi dengan luas zona tersebut dalam meter persegi untuk memperoleh estimasi kepadatan, yang kemudian dipetakan ke tingkat pelayanan sesuai klasifikasi Fruin dan Permen PUPR 2014.

2.3 Analisis Perbandingan Metode

Pemilihan metode deteksi objek untuk sistem pemantauan di kawasan Malioboro tidak dapat dilepaskan dari kebutuhan spesifik permasalahan yang dihadapi. Sistem harus melakukan inferensi secara *real-time* pada perangkat dengan sumber daya terbatas, mampu mendeteksi pejalan kaki sekaligus kelas kendaraan lokal yang tidak tercakup dalam model umum, dapat dilatih dari *dataset* kustom berukuran terbatas, serta layak diterapkan pada lingkungan operasional. Empat kebutuhan inilah yang menjadi tolok ukur dalam membandingkan metode-metode yang tersedia. Subbab ini meninjau kelebihan dan kekurangan tiap pendekatan terhadap tolok ukur tersebut, lalu menjustifikasi metode yang dipilih.

2.3.1 Perbandingan Pendekatan Deteksi Objek

Pendekatan *two-stage* yang diwakili oleh Faster R-CNN memisahkan deteksi menjadi dua tahap, yaitu pembangkitan usulan wilayah (*region proposal*) dan klasifikasi pada tiap usulan tersebut [18]. Pemisahan ini menghasilkan akurasi lokalisasi yang tinggi, tetapi rangkaian dua tahap membuat latensi inferensi meningkat sehingga sulit memenuhi kebutuhan *real-time* pada perangkat berdaya rendah. Untuk sistem yang memproses aliran kamera secara terus-menerus, latensi yang tinggi menjadi hambatan utama.

Pendekatan berbasis *transformer* yang diwakili RT-DETR menghilangkan tahap *non-maximum suppression* (NMS) dan menjadikan proses deteksi bersifat *end-to-end* [23]. Pada skala server, RT-DETR menawarkan keseimbangan kecepatan dan akurasi yang kuat. Varian RT-DETR-R50 mencapai 53,1% AP pada COCO *val2017* dengan 108 FPS pada GPU T4, mengungguli detektor YOLO sekelasnya dalam dua metrik tersebut [23]. Keterbatasannya muncul pada sisi efisiensi model. Varian terkecil RT-DETR, yaitu RT-DETR-R18, memiliki sekitar 20 juta parameter dan tidak menyediakan tier ringan setara kelas *nano*. Selain itu, detektor berbasis *transformer* cenderung membutuhkan data pelatihan yang lebih banyak untuk konvergen, sehingga kurang sesuai untuk *dataset* kustom berukuran terbatas.

Pendekatan *one-stage* berbasis CNN yang diwakili YOLO memprediksi kelas dan kotak pembatas dalam satu kali proses maju, sehingga inferensinya cepat [19]. Keluarga

YOLO menyediakan rentang ukuran model yang lebar, mulai dari tier *nano* dengan sekitar 2,6 juta parameter hingga varian terbesar [21, 22]. Pada sisi akurasi, varian terbesar YOLO11 mencapai 54,7% mAP pada COCO dengan jumlah parameter yang lebih sedikit dibanding varian transformer setara, sehingga anggapan bahwa YOLO selalu kalah akurat terhadap *transformer* tidak lagi berlaku mutlak. Ketersediaan tier ringan membuat YOLO dapat dijalankan pada perangkat terbatas, sementara ekosistem dan bobot *pretrained* yang matang memudahkan pelatihan ulang pada *dataset* kustom.

Tabel 2.2. Perbandingan pendekatan deteksi objek terhadap kebutuhan sistem pemantauan.

Aspek	Faster R-CNN	RT-DETR	YOLO (v8/v11)
Pendekatan	<i>Two-stage CNN</i>	<i>Transformer end-to-end</i>	<i>One-stage CNN</i>
Kecepatan inferensi	Rendah	Tinggi	Tinggi
Varian teringan	Tidak ada tier ringan	≈20 juta parameter	≈2,6 juta parameter
Kesesuaian perangkat terbatas	Kurang (latensi tinggi)	GPU server	Perangkat terbatas
Kebutuhan data latih	Sedang	Tinggi	Sedang

Mengacu pada empat tolok ukur permasalahan, YOLO memberikan kesesuaian terbaik. Faster R-CNN tersisih karena latensi yang tinggi, sedangkan RT-DETR, meski unggul pada skala server, tidak menyediakan tier ringan dan lebih menuntut data pelatihan. Penting dicatat bahwa keputusan ini bukan karena YOLO unggul secara mutlak di semua kondisi, melainkan karena ketersediaan tier ringan, efisiensi parameter, dan kematangan ekosistem YOLO selaras dengan kendala *real-time*, perangkat terbatas, dan *dataset* kustom yang menjadi ciri penelitian ini.

2.3.2 Pemilihan Varian YOLO untuk Penelitian

Setelah keluarga YOLO ditetapkan, langkah berikutnya adalah memilih versi yang dibandingkan. Penelitian ini menggunakan YOLOv8 dan YOLO11 karena keduanya merupakan model unggulan resmi dari Ultralytics yang berbagi kerangka pelatihan, format data, alur augmentasi, dan antarmuka pemrograman yang identik [21, 22]. Kesamaan ini membuat perbedaan performa di antara keduanya dapat diatribusikan ke arsitektur, bukan ke perbedaan implementasi *framework*, sehingga perbandingan menjadi terkontrol secara metodologis.

Versi YOLO lain sengaja tidak dimasukkan untuk menjaga kontrol tersebut. YOLOv9 dikembangkan dari basis kode YOLOv5 dan diposisikan sebagai model

eksperimental, sedangkan YOLOv10 dikembangkan oleh kelompok peneliti yang berbeda dengan mekanisme pelatihan tanpa NMS. Versi yang lebih baru seperti YOLOv12 belum memiliki kematangan tooling dan dukungan yang setara. Memasukkan versi-versi tersebut ke dalam perbandingan akan menambahkan variabel pengganggu berupa perbedaan asal basis kode dan filosofi desain. Membatasi perbandingan pada dua model unggulan Ultralytics yang setara justru menghasilkan perbandingan yang lebih valid.

Empat ukuran model, yaitu *nano* (n), *small* (s), *medium* (m), dan *large* (l), diuji pada tiap versi untuk memetakan keterkaitan antara ukuran model, akurasi, dan kecepatan yang relevan dengan kebutuhan *real-time*. Varian terbesar (x) dikecualikan karena keterbatasan perangkat pelatihan dan deteksi serta tidak praktis untuk penerapan *real-time*, dan pengecualian ini dinyatakan sebagai batasan penelitian.

Berdasarkan analisis di atas, metode yang dipilih adalah studi perbandingan YOLOv8 dan YOLO11 pada empat ukuran model, dilatih dan dievaluasi pada *dataset* kustom kawasan Malioboro. Model dengan keseimbangan akurasi dan kecepatan terbaik akan dipilih untuk diterapkan pada sistem pemantauan. Rincian tahapan pelatihan, konfigurasi, dan evaluasi diuraikan pada Bab III.

BAB III

METODE PENELITIAN

Bab ini menjelaskan tahapan yang ditempuh untuk menjawab tujuan penelitian, mulai dari penyiapan data hingga implementasi sistem pemantauan.

3.1 Gambaran Umum Penelitian

Penelitian ini dilaksanakan melalui tujuh tahap berurutan yang membentuk satu alur dari penyediaan data hingga sistem yang berjalan, seperti ditunjukkan pada Gambar 3.1. Tahap pertama adalah pengumpulan data citra dari aliran kamera pengawas kawasan Malioboro. Citra yang terkumpul kemudian dianotasi pada tahap kedua menggunakan pendekatan semi-otomatis untuk menghasilkan label sembilan kelas objek. Tahap ketiga membersihkan anotasi dari kesalahan geometris dan membagi data menjadi himpunan latih, validasi, dan uji. Tahap keempat melatih delapan varian model YOLOv8 dan YOLO11 dengan konfigurasi identik untuk membandingkannya secara terkontrol. Tahap kelima mengevaluasi performa tiap varian menggunakan sejumlah metrik dan memilih model dengan keseimbangan akurasi serta kecepatan terbaik. Tahap keenam menyetel *hyperparameter* model terpilih untuk mengoptimasi performanya. Tahap ketujuh menerapkan model hasil penyetelan ke dalam sistem pemantauan berbasis web yang memproses video secara waktu nyata dan menyajikan informasi kepadatan beserta notifikasinya.


Ketujuh tahap tersebut bersifat berurutan, yaitu keluaran satu tahap menjadi masukan bagi tahap berikutnya. Kualitas anotasi pada tahap kedua dan ketiga menetapkan batas atas performa yang dapat dicapai model pada tahap keempat, sedangkan performa model menentukan keandalan informasi kepadatan yang disajikan sistem pada tahap ketujuh. Karena keterkaitan tersebut, tahap penyiapan data dan pelatihan model diuraikan secara rinci pada subbab-subbab berikutnya sebelum perancangan sistem dibahas pada bagian akhir bab ini.

3.2 Alat dan Bahan Tugas Akhir

Subbab ini menjelaskan perangkat keras dan perangkat lunak yang digunakan sepanjang penelitian. Spesifikasi dicantumkan agar tahap pelatihan dan pengujian dapat diulang pada lingkungan yang setara.

3.2.1 Perangkat Keras

Pelatihan model dilakukan pada lingkungan komputasi performa tinggi (*high-performance computing*, HPC) milik Departemen Teknik Elektro dan Teknologi



Gambar 3.1. Alur tahapan penelitian.

Informasi, Fakultas Teknik, Universitas Gadjah Mada. Lingkungan ini menyediakan GPU NVIDIA Tesla V100-SXM2 dengan memori 32 GB, yang memungkinkan pelatihan seluruh varian model termasuk ukuran *large* tanpa kendala keterbatasan memori.

Perancangan dan pengujian sistem dilakukan pada laptop dengan prosesor AMD Ryzen 5 5600H, GPU NVIDIA GeForce GTX 1650 bermemori 4 GB, RAM 16 GB (2×8 GB DDR4-3200), dan sistem operasi Windows 11 Home Single Language 64-bit. Spesifikasi ini mewakili kelas perangkat dengan sumber daya terbatas sebagai target penerapan waktu nyata.

3.2.2 Perangkat Lunak

Pelatihan dan inferensi model menggunakan pustaka Ultralytics yang menyediakan implementasi YOLOv8 dan YOLO11 di atas kerangka kerja PyTorch. Proses anotasi data dilakukan pada platform Roboflow, sedangkan pembacaan dan pemrosesan *frame* video dilakukan dengan pustaka OpenCV. Versi perangkat lunak utama yang digunakan pada lingkungan pelatihan dirangkum pada Tabel 3.1.

Tabel 3.1. Versi perangkat lunak utama yang digunakan pada lingkungan pelatihan.

Perangkat lunak	Versi
Python	3.10.12
PyTorch	2.2.0a0+81ea7a4
CUDA	12.3
Ultralytics	8.4.63
OpenCV (cv2)	4.9.0
Roboflow	Platform anotasi berbasis web
Kerangka kerja sistem web	[lengkapi setelah ditentukan]

3.3 Pengumpulan Data

Pengumpulan data bertujuan membangun kumpulan citra primer yang mewakili kondisi nyata kawasan Malioboro sebagai bahan pelatihan dan pengujian model deteksi. Subbab ini menjelaskan sumber dan mekanisme pengambilan citra, penjadwalan pengambilan untuk memperoleh variasi kondisi, serta penyaringan citra yang tidak layak digunakan.

3.3.1 Sumber dan Mekanisme Pengambilan *Frame*

Data primer penelitian berupa citra yang diambil dari aliran video langsung 22 kamera pengawas publik di kawasan Malioboro yang dikelola Pemerintah Kota Yogyakarta. Aliran video disediakan dalam format *HTTP Live Streaming* (HLS) melalui berkas *playlist* berekstensi `.m3u8`, sehingga setiap kamera dapat diakses sebagai sumber video daring.

Pengambilan citra dilakukan secara otomatis menggunakan program yang ditulis dengan bahasa Python. Program memiliki penjadwal internal sendiri, yaitu dijalankan satu kali lalu menunggu hingga slot waktu berikutnya tanpa bergantung pada penjadwal sistem eksternal. Pada setiap slot, program mengambil satu *frame* dari tiap kamera.

Pengambilan satu *frame* dari aliran HLS memerlukan penanganan khusus karena aliran menyimpan *buffer* yang berisi *frame* lama. Program membuka aliran, menunggu dua detik agar koneksi stabil, membuang 30 *frame* pertama dari *buffer*, lalu mengambil satu *frame* terkini. Jika pengambilan gagal, proses diulang hingga tiga kali sebelum kamera tersebut ditandai gagal. Setiap *frame* yang berhasil disimpan dalam format JPEG dengan kualitas 92, dan diberi nama berkas yang memuat nomor kamera, tanggal, dan waktu pengambilan, sehingga tiap citra dapat diidentifikasi sumber serta waktunya tanpa berkas catatan terpisah.

3.3.2 Penjadwalan dan Variasi Kondisi

Pengumpulan data berlangsung selama satu pekan, yaitu 30 April hingga 6 Mei 2026. Rentang waktu ini dipilih agar data mencakup variasi kondisi antar hari, antar jam, dan antar cuaca, sehingga model dilatih pada keragaman situasi yang mendekati kondisi nyata.

Dalam satu hari, pengambilan dilakukan pada 11 slot waktu yang mewakili rentang kepadatan dan pencahayaan, mulai dari dini hari yang sepi, meningkat sepanjang siang, hingga memuncak pada sore dan malam hari sesuai karakter kawasan wisata Malioboro. Rincian slot ditunjukkan pada Tabel 3.2.

Tabel 3.2. Slot waktu pengambilan citra dalam satu hari.

Pukul	Label Slot	Keterangan Kondisi
00.00	<i>midnight</i>	keramaian larut malam mulai menurun
02.00	<i>dawn</i>	kondisi paling sepi
06.00	<i>early_morning</i>	aktivitas masih rendah
08.00	<i>morning</i>	aktivitas pagi meningkat
10.00	<i>midmorning</i>	kunjungan wisatawan meningkat
12.00	<i>noon</i>	keramaian siang
14.00	<i>afternoon</i>	keramaian siang berlanjut
16.00	<i>late_afternoon</i>	keramaian menjelang sore
18.00	<i>evening</i>	awal puncak keramaian malam
20.00	<i>night</i>	puncak keramaian malam
22.00	<i>late_night</i>	keramaian mulai menurun

Dengan 11 slot, 22 kamera, dan 7 hari, jumlah *frame* yang ditargetkan secara teoretis adalah 1.694. Sebagian percobaan pengambilan gagal akibat gangguan koneksi aliran, sehingga jumlah citra yang berhasil dikumpulkan adalah 1.581. Seluruh citra tersebut digunakan tanpa penyaringan lebih lanjut, lalu dilanjutkan ke tahap anotasi.

3.4 Anotasi Data

Anotasi bertujuan memberi label berupa kotak pembatas dan kelas pada setiap objek di dalam citra. Subbab ini menjelaskan strategi anotasi yang dipilih akibat keterbatasan waktu, perbandingan beberapa pendekatan pelabelan otomatis untuk menentukan *baseline*, serta anotasi manual dan koreksi yang melengkapinya. Seluruh proses anotasi dikerjakan pada platform Roboflow.

3.4.1 Strategi Anotasi Semi-Otomatis

Rencana awal penelitian adalah menganotasi seluruh citra secara manual agar kualitas label terjaga. Setelah 329 citra selesai dianotasi manual, waktu yang tersedia

dinilai tidak mencukupi untuk menyelesaikan seluruh 1.581 citra dengan cara yang sama dalam jadwal penyusunan skripsi. Oleh karena itu, sisa 1.252 citra dianotasi menggunakan pendekatan semi-otomatis, yaitu pelabelan otomatis oleh model *pretrained* yang kemudian diperiksa dan dikoreksi secara manual [26].

Dengan pembagian tersebut, 329 citra hasil anotasi manual digunakan sebagai data dengan label yang dianggap bersih, sedangkan 1.252 citra hasil anotasi semi-otomatis digunakan sebagai data latih. Pembagian ke dalam himpunan latih, validasi, dan uji diuraikan pada Subbab 3.5.

3.4.2 Perbandingan Pendekatan Pelabelan Otomatis

Tahap pelabelan otomatis memerlukan model dasar yang menghasilkan kotak pembatas awal. Tiga kombinasi model diuji pada 1.252 citra latih untuk menentukan pilihan terbaik. Pada ketiga kombinasi, kelas bajaj dideteksi oleh model YOLOv12s yang telah dilatih pada dataset BMD-45 [9], sedangkan kelas lain dideteksi oleh model dasar yang berbeda, yaitu SAM3 [27], YOLO11x, atau YOLOv8x. Pelabelan dengan SAM3 dilakukan melalui layanan Roboflow API. Jumlah *instance* hasil tiap kombinasi dirangkum pada Tabel 3.3.

Tabel 3.3. Jumlah *instance* hasil tiga kombinasi pelabelan otomatis pada 1.252 citra latih.

Kelas	SAM3	YOLO11x	YOLOv8x
andong	0	0	0
bajaj	112	112	112
becak	0	0	0
sepeda	3.916	277	265
bus	549	114	123
mobil	11.964	1.789	1.821
motor	32.074	1.894	2.124
orang	81.000	7.784	9.803
truk	619	276	250
Total	130.234	12.246	14.498


Dua kelas, yaitu andong dan becak, tidak terdeteksi sama sekali oleh ketiga kombinasi karena tidak tersedia pada model dasar mana pun, sementara bajaj menghasilkan jumlah yang sama, yaitu 112, karena memakai model yang identik. Perbedaan utama terletak pada kelas umum. Kombinasi berbasis SAM3 menghasilkan 130.234 *instance*, hampir sembilan kali lipat dibanding YOLOv8x, dengan kelas orang saja mencapai 81.000. SAM3 dirancang untuk menemukan seluruh *instance* dari suatu konsep sekaligus, sehingga pada citra yang padat cenderung menghasilkan deteksi yang sangat banyak dan didominasi *false positive*. Akibatnya, biaya koreksi manualnya justru lebih besar daripada manfaatnya.

Kombinasi YOLOv8x dipilih sebagai *baseline*. Dibandingkan YOLO11x, YOLOv8x bersifat lebih agresif, terlihat dari jumlah *instance* yang lebih banyak, yaitu 14.498 berbanding 12.246. Sifat agresif ini menguntungkan pada tahap awal pelabelan karena menghapus *false positive* lebih cepat daripada menambahkan deteksi yang terlewat secara manual. SAM3 tidak dipilih karena tingkat deteksi berlebihnya terlalu tinggi, sehingga *noise* yang dihasilkan tidak sebanding dengan waktu koreksi yang diperlukan.

3.4.3 Anotasi Manual dan Koreksi

Hasil pelabelan otomatis melengkapi sebagian besar kelas, tetapi belum mencakup andong dan becak yang tidak terdeteksi oleh model dasar mana pun. Kedua kelas tersebut dianotasi secara manual penuh pada citra latih.

Selain penambahan dua kelas tersebut, hasil *baseline* YOLOv8x ditinjau dan dikoreksi secara manual semaksimal mungkin. Gambar 3.2 menunjukkan salah satu contoh kesalahan, yaitu tiga bangku taman yang terdeteksi sebagai objek (*false positive*).



Gambar 3.2. Contoh kesalahan deteksi tiga bangku taman yang terdeteksi sebagai objek.

Selain contoh pada gambar tersebut, penulis menemukan beberapa pola kesalahan yang berulang. Kotak pembatas kelas bus dan truk sering tumpang tindih pada objek yang sama. Kelas bajaj kadang terlabeli sebagai truk, sedangkan becak terkadang terdeteksi sebagai motor. Latar belakang citra juga beberapa kali terdeteksi sebagai salah satu dari sembilan kelas. Seluruh kesalahan tersebut diperbaiki secara manual, baik dengan menghapus deteksi yang keliru, memperbaiki label kelas, maupun menyesuaikan kotak pembatas.

Anotasi manual dan koreksi ini mengubah jumlah dan komposisi label dari hasil *baseline*. Distribusi akhir setelah pembersihan beserta pembagian data diuraikan pada Subbab 3.5.

3.5 Pembersihan dan Pembagian Dataset

Sebelum digunakan untuk pelatihan dan evaluasi, anotasi dibagi ke dalam tiga himpunan lalu dibersihkan dari kesalahan geometris. Subbab ini menjelaskan pembagian data, proses pembersihan anotasi, serta distribusi kelas akhir beserta ketidakseimbangannya.

3.5.1 Pembagian *Train*, *Validation*, dan *Test*

Data dibagi ke dalam tiga himpunan, yaitu latih (*train*), validasi (*validation*), dan uji (*test*). Pembagian mengikuti cara anotasi yang dijelaskan pada Subbab 3.4. Sebanyak 1.252 citra hasil anotasi semi-otomatis digunakan sebagai himpunan latih, sedangkan 329 citra hasil anotasi manual dibagi menjadi 165 citra validasi dan 164 citra uji.

Penempatan seluruh citra ber-anotasi manual pada himpunan validasi dan uji dilakukan dengan sengaja. Kedua himpunan tersebut menjadi acuan pengukuran performa model, sehingga keduanya perlu memiliki label yang andal. Dengan label manual pada validasi dan uji, performa model diukur terhadap acuan yang tepercaya, terlepas dari kemungkinan kesalahan yang masih tersisa pada label semi-otomatis di himpunan latih.

3.5.2 Pembersihan Geometris Anotasi

Anotasi dibersihkan dari kotak pembatas yang tidak valid secara geometris menggunakan lima filter. Kotak yang sangat kecil disaring karena objek dengan luas di bawah 0,1% luas citra setara dengan kurang dari 20×20 piksel setelah citra diskala ke 640×640 , sehingga terlalu kecil untuk dipelajari dan sejalan dengan perhatian terhadap objek berukuran sangat kecil pada COCO [25]. Kotak yang menutupi lebih dari 90% luas citra disaring sebagai kesalahan anotasi, sedangkan kotak dengan rasio sisi yang ekstrem, baik terlalu tipis maupun terlalu lebar, juga disingkirkan. Rincian ambang tiap filter ditunjukkan pada Tabel 3.4.

Tabel 3.4. Filter pembersihan kotak pembatas.

Kriteria	Ambang	Tindakan
Luas ternormalisasi minimum	0,001	buang kotak $< 0,1\%$ luas citra
Luas ternormalisasi maksimum	0,90	buang kotak $> 90\%$ luas citra
Rasio sisi minimum	0,15	buang kotak terlalu tipis (lebar/tinggi $< 0,15$)
Rasio sisi maksimum	10,0	buang kotak terlalu lebar (lebar/tinggi > 10)
Ukuran ternormalisasi maksimum	1,0	buang kotak yang melampaui batas citra

Penerapan kelima filter mengurangi sebagian kecil anotasi pada tiap himpunan. Tabel 3.5 merangkum jumlah *instance* sebelum dan sesudah pembersihan. Sebagian besar anotasi dipertahankan, dengan kelas orang paling banyak terdampak karena banyaknya kotak berukuran kecil pada citra kerumunan yang padat.

Tabel 3.5. Jumlah *instance* sebelum dan sesudah pembersihan pada tiap himpunan.

Himpunan	Sebelum	Sesudah	Dibuang	Dipertahankan
Latih	18.536	17.500	1.036	94,4%
Validasi	5.372	4.222	1.150	78,6%
Uji	5.605	4.288	1.317	76,5%

3.5.3 Distribusi dan Ketidakseimbangan Kelas

Distribusi kelas akhir setelah pembersihan ditunjukkan pada Tabel 3.6. Distribusi ini sangat tidak seimbang. Pada himpunan latih, kelas orang memiliki 10.694 *instance*, sedangkan kelas truk hanya 45, sehingga rasio antara kelas terbanyak dan paling sedikit mencapai sekitar 237 banding 1.

Tabel 3.6. Distribusi jumlah *instance* tiap kelas setelah pembersihan.

Kelas	Latih	Validasi	Uji
andong	611	76	95
bajaj	96	17	15
becak	2.277	464	445
sepeda	162	15	28
bus	92	13	10
mobil	1.695	430	336
motor	1.828	444	453
orang	10.694	2.759	2.898
truk	45	4	8
Total	17.500	4.222	4.288

Ketidakseimbangan ini mencerminkan komposisi objek yang sebenarnya di kawasan Malioboro, yaitu pejalan kaki, becak, motor, dan mobil mendominasi, sedangkan truk, bus, bajaj, dan sepeda jauh lebih jarang muncul. Ketidakseimbangan kelas merupakan persoalan yang umum pada deteksi objek dan dapat menurunkan performa pada kelas minoritas [17]. Pengaruh ketidakseimbangan ini terhadap performa deteksi tiap kelas dianalisis pada Bab IV.

3.6 Pelatihan dan Perbandingan Model

Pelatihan bertujuan menghasilkan model deteksi terbaik dari dua keluarga arsitektur yang dibandingkan, yaitu YOLOv8 dan YOLO11. Subbab ini menjelaskan konfigurasi pelatihan, prapemrosesan dan augmentasi data masukan, serta skema pelatihan dan perbandingan model.

3.6.1 Konfigurasi Pelatihan

Pelatihan dilakukan pada lingkungan HPC dengan GPU NVIDIA Tesla V100-SXM2 32 GB yang dijelaskan pada Subbab 3.2, menggunakan implementasi resmi Ultralytics. Delapan varian model dilatih, yaitu YOLOv8 dan YOLO11 masing-masing pada empat ukuran, yaitu *nano* (n), *small* (s), *medium* (m), dan *large* (l).

Tiap varian diinisialisasi dari bobot *pretrained* pada dataset COCO, lalu dilatih ulang pada dataset kawasan Malioboro melalui mekanisme *transfer learning*. Seluruh varian dilatih dengan nilai *hyperparameter* yang identik agar perbandingan bersifat adil, sehingga perbedaan performa dapat diatribusikan pada arsitektur, bukan pada konfigurasi pelatihan. Karena *optimizer* diatur ke mode *auto*, Ultralytics menentukan jenis *optimizer*, yaitu AdamW, beserta *learning rate* dan *momentum* awalnya secara otomatis. Nilai *hyperparameter* selengkapnya dirangkum pada Tabel 3.7.

Penggunaan konfigurasi bawaan dan mode *auto* dipilih atas dua pertimbangan. Pertama, tujuan tahap ini adalah membandingkan dua keluarga arsitektur secara adil, bukan mencari kombinasi *hyperparameter* optimal untuk tiap varian. Menyetel *hyperparameter* secara berbeda untuk tiap model justru akan mencampuradukkan efek arsitektur dengan efek konfigurasi, sehingga perbedaan performa tidak lagi dapat diatribusikan pada arsitektur. Prinsip memakai pengaturan standar bawaan implementasi resmi alih-alih menyetel manual tiap model juga diterapkan pada penelitian *benchmark* detektor pada dataset CCTV kendaraan, yang mengikuti konfigurasi yang direkomendasikan untuk tiap model demi perbandingan yang adil [9]. Penelitian ini menerapkan prinsip yang sama melalui mode *auto* Ultralytics, yang menetapkan *optimizer*, *learning rate*, dan *momentum* secara otomatis tanpa penyetelan manual. Kedua, performa deteksi cenderung tidak peka terhadap perubahan *hyperparameter* dalam rentang yang luas. Pada Faster R-CNN, perubahan bobot fungsi *loss* sebesar dua orde magnitudo hanya mengubah mAP sekitar 1% [18], sehingga penyetelan manual tiap *hyperparameter* tidak diharapkan mengubah urutan perbandingan antar arsitektur secara berarti. Optimasi terhadap satu *hyperparameter* tertentu tetap dilakukan, tetapi hanya pada model terbaik setelah model tersebut terpilih, sebagaimana diuraikan pada Subbab 3.8.

Tabel 3.7. Konfigurasi *hyperparameter* pelatihan.

Parameter	Nilai
Jumlah epoch	100
<i>Patience (early stopping)</i>	20
<i>Batch size</i>	otomatis (<i>auto-batch</i>)
Ukuran citra masukan	640×640
<i>Optimizer</i>	AdamW (dipilih otomatis, mode <i>auto</i>)
<i>Learning rate</i> awal	ditentukan otomatis oleh mode <i>auto</i>
Faktor <i>learning rate</i> akhir (lrf)	0,01
<i>Momentum</i>	ditentukan otomatis oleh mode <i>auto</i>
<i>Weight decay</i>	0,0005
<i>Warmup epoch</i>	3
Bobot awal	<i>pretrained</i> COCO
<i>Mixed precision (AMP)</i>	aktif
<i>Seed</i>	0 (deterministik)

3.6.2 Prapemrosesan dan Augmentasi

Sebelum masuk ke model, setiap citra diskala ke ukuran masukan 640×640 piksel. Augmentasi data dilakukan menggunakan pengaturan bawaan Ultralytics, yang diterapkan secara seragam pada seluruh varian agar perbandingan tidak dipengaruhi perbedaan perlakuan augmentasi.

Augmentasi yang aktif meliputi *mosaic* dengan peluang penuh yang dimatikan pada 10 epoch terakhir, pembalikan horizontal dengan peluang 0,5, penskalaan acak sebesar 0,5, pergeseran sebesar 0,1, penyesuaian warna pada ruang HSV, *RandAugment*, serta penghapusan acak (*random erasing*) sebesar 0,4. Beberapa augmentasi tidak diaktifkan, yaitu rotasi, pembalikan vertikal, *mixup*, *cutmix*, dan *copy-paste*, sesuai nilai bawaan Ultralytics.

3.6.3 Skema Pelatihan dan Perbandingan

Kedelapan varian dilatih dengan konfigurasi identik selama 100 epoch, dengan *early stopping* yang menghentikan pelatihan apabila performa pada data validasi tidak membaik selama 20 epoch berturut-turut. Mekanisme ini memungkinkan pelatihan berhenti sebelum mencapai 100 epoch jika model telah konvergen.

Performa kedelapan varian kemudian dibandingkan menggunakan metrik yang dijelaskan pada Subbab 3.7. Model dengan keseimbangan akurasi dan kecepatan terbaik dipilih untuk diterapkan pada sistem pemantauan. Hasil pelatihan dan perbandingan tiap varian disajikan pada Bab IV.

3.7 Evaluasi Model

Evaluasi bertujuan mengukur dan membandingkan performa kedelapan varian model serta memilih model terbaik untuk diterapkan. Subbab ini menjelaskan metrik yang digunakan beserta desain evaluasi dan kriteria pemilihan model.

3.7.1 Metrik Evaluasi

Performa deteksi diukur menggunakan beberapa metrik yang definisinya telah diuraikan pada Bab II, yaitu *precision*, *recall*, F1, serta *mean Average Precision* (mAP). Metrik mAP dihitung pada dua ambang *Intersection over Union* (IoU), yaitu mAP50 pada ambang 0,5 dan mAP50-95 sebagai rata-rata pada ambang 0,5 hingga 0,95 dengan langkah 0,05. mAP50 menilai kemampuan deteksi dengan toleransi lokalisasi yang longgar, sedangkan mAP50-95 menuntut lokalisasi yang lebih tepat sehingga menjadi ukuran kualitas yang lebih ketat.

Skor F1 dihitung sebagai rata-rata harmonik *precision* dan *recall*, baik secara keseluruhan maupun per kelas. F1 per kelas digunakan untuk menganalisis pengaruh ketidakseimbangan jumlah *instance* terhadap performa tiap kelas, sesuai tujuan penelitian. Seluruh metrik akurasi dihitung pada himpunan uji yang berlabel manual agar pengukuran tidak bias.

Selain akurasi, kecepatan inferensi diukur dalam jumlah *frame* per detik (FPS) atau waktu pemrosesan per citra pada perangkat penerapan, yaitu laptop dengan GPU GTX 1650. Metrik ini menilai kelayakan model untuk pemantauan secara waktu nyata.

3.7.2 Desain Evaluasi dan Pemilihan Model

Evaluasi dilakukan dengan membandingkan kedelapan varian model pada metrik di atas menggunakan himpunan uji. Himpunan validasi digunakan selama pelatihan untuk *early stopping*, sedangkan himpunan uji yang tidak pernah dilihat model selama pelatihan menjadi dasar perbandingan akhir.

Analisis tidak hanya melihat performa keseluruhan, tetapi juga performa tiap kelas melalui F1 per kelas, untuk menilai sejauh mana ketidakseimbangan kelas memengaruhi deteksi pada kelas mayoritas maupun minoritas.

Model terbaik dipilih berdasarkan keseimbangan antara kualitas deteksi dan kecepatan inferensi pada perangkat penerapan, bukan semata akurasi tertinggi, karena sistem harus berjalan secara waktu nyata pada perangkat dengan sumber daya terbatas. Model terpilih kemudian dioptimasi lebih lanjut melalui penyetelan *hyperparameter* sebelum diterapkan, sebagaimana diuraikan pada Subbab 3.8. Hasil evaluasi dan perbandingan kedelapan varian disajikan pada Bab IV.

3.8 Penyetelan Hyperparameter Model Terpilih

Pemilihan model pada Subbab 3.7 menghasilkan satu varian terbaik yang menyeimbangkan kualitas deteksi dan kecepatan inferensi. Subbab ini menjelaskan upaya meningkatkan performa varian terpilih melalui penyetelan *hyperparameter*, beserta dasar pemilihan *hyperparameter* yang disetel, konfigurasi yang digunakan, dan analisis hasilnya. Penyetelan ini diposisikan sebagai langkah optimasi terhadap satu model terpilih, bukan pelatihan ulang seluruh varian, sehingga lingkupnya tetap terkendali.

3.8.1 Dasar dan Strategi Penyetelan

Penyetelan diarahkan pada satu *hyperparameter* tunggal, yaitu ukuran citra masukan (*image size*), yang dinaikkan dari 640 menjadi 960 piksel. Pilihan ini didasarkan pada karakteristik kelemahan model hasil pelatihan awal. Hasil evaluasi menunjukkan *recall* yang rendah pada hampir seluruh kelas dan performa terlemah pada kelas sepeda, pola yang khas untuk objek berukuran kecil dan berjarak jauh dari kamera. Banyak objek seperti orang dan motor di kejauhan tidak terdeteksi. Menaikkan resolusi masukan menysar kelemahan ini secara langsung, karena objek kecil terwakili oleh lebih banyak piksel pada resolusi yang lebih tinggi sehingga lebih mudah dikenali.

Dasar ini didukung oleh temuan empiris pada literatur deteksi objek. Hasil pada *benchmark* MIO-TCD menunjukkan bahwa menaikkan resolusi masukan dari 300 menjadi 512 piksel meningkatkan mAP sebesar 4%, dan tantangan terbesar pada dataset tersebut berasal dari kelas kendaraan kecil dan pejalan kaki yang mudah tertukar dengan kategori sepeda dan motor karena ukurannya yang kecil [28]. Pola kesulitan yang sama muncul pada dataset penelitian ini. Keterbatasan deteksi objek kecil juga diakui sejak arsitektur YOLO awal, yang kesulitan pada objek kecil yang muncul berkelompok karena penggunaan fitur yang relatif kasar akibat banyaknya lapisan *downsampling* [19]. Tinjauan terhadap masalah ketidakseimbangan pada deteksi objek juga menegaskan adanya kecondongan distribusi ke arah objek berukuran kecil yang memengaruhi performa deteksi [17].

Penyetelan dilakukan dengan menjaga satu variabel berubah. Seluruh *hyperparameter* lain dipertahankan identik dengan konfigurasi pelatihan awal pada Tabel 3.7, dan model diinisialisasi dari bobot *pretrained* COCO yang sama, bukan dari bobot hasil pelatihan pada dataset Malioboro. Dengan cara ini, setiap perbedaan performa antara model pada resolusi 640 dan 960 dapat diatribusikan murni pada perubahan resolusi, bukan pada faktor lain.

3.8.2 Hasil Penyetelan dan Analisis

Model hasil penyetelan berhenti pada epoch ke-79 akibat *early stopping*, sebanding dengan model awal yang berhenti pada kisaran epoch yang serupa, sehingga keduanya

sama-sama mencapai konvergensi sebelum batas 100 epoch. Perbandingan performa keseluruhan pada himpunan uji disajikan pada Tabel 3.8.

Tabel 3.8. Perbandingan performa yolo11l pada resolusi 640 dan 960 (himpunan uji)

Konfigurasi	mAP50	mAP50-95	Precision	Recall	Rerata F1
Resolusi 640 (awal)	0,6062	0,4012	0,7146	0,5438	0,5962
Resolusi 960 (setelan)	0,6497	0,4413	0,7575	0,6217	0,6739
Selisih	+0,0435	+0,0401	+0,0429	+0,0779	+0,0777

Seluruh metrik meningkat. Nilai mAP50-95 naik sebesar 0,0401 atau sekitar 4 poin persentase, peningkatan yang besar untuk satu perubahan *hyperparameter*. Kenaikan terbesar terjadi pada *recall*, yaitu 0,0779, yang sesuai dengan hipotesis bahwa resolusi lebih tinggi membuat lebih banyak objek berhasil terdeteksi alih-alih terlewat. Pola ini memperkuat dugaan bahwa kelemahan utama model awal adalah objek kecil yang tidak tertangkap pada resolusi rendah.

Perbaikan paling jelas terlihat pada analisis F1 per kelas, yang disajikan pada Tabel 3.9. Kelas sepeda, yang menjadi kelas terlemah pada model awal, naik sebesar 0,202 poin F1, sementara kelas bajaj naik sebesar 0,232 poin, peningkatan terbesar di antara seluruh kelas. Kedua kelas ini berisi objek berukuran kecil hingga sedang dengan jumlah *instance* yang sedikit. Sebaliknya, kelas andong dan mobil yang berisi objek relatif besar dan sudah terdeteksi baik pada resolusi 640 justru turun tipis, masing-masing sebesar 0,014 dan 0,006 poin. Pola ini konsisten dengan dasar teoretis penyetelan, yaitu kenaikan resolusi membantu objek kecil dan hampir tidak berpengaruh, atau sedikit merugikan, pada objek yang sudah berukuran besar dan jelas.

Tabel 3.9. Perbandingan F1 per kelas yolo11l pada resolusi 640 dan 960 (himpunan uji)

Kelas	F1 (640)	F1 (960)	Selisih
andong	0,799	0,785	−0,014
bajaj	0,428	0,660	+0,232
becak	0,769	0,814	+0,045
sepeda	0,270	0,472	+0,202
bus	0,503	0,620	+0,117
mobil	0,820	0,814	−0,006
motor	0,565	0,621	+0,056
orang	0,643	0,654	+0,011
truk	0,568	0,625	+0,057
Rerata	0,596	0,674	+0,078

Peningkatan akurasi ini disertai biaya komputasi. Waktu pelatihan naik dari 34,9 menit menjadi 84,2 menit, atau sekitar 141%, akibat ukuran citra yang lebih besar. Ukuran

model praktis tidak berubah, yaitu 51,25 MB, karena arsitektur tetap sama dan hanya resolusi masukan yang berbeda. Biaya pelatihan ini bersifat sekali jalan dan tidak menjadi beban berulang saat sistem dioperasikan.

Biaya yang lebih menentukan untuk kelayakan penerapan adalah kecepatan inferensi. Pada GPU V100, model resolusi 960 mencapai 25,46 milidetik per citra atau setara 39,3 *frame* per detik, yang masih jauh di atas ambang pemantauan waktu nyata. Akan tetapi, perangkat penerapan yang dituju adalah laptop dengan GPU GTX 1650 yang jauh lebih terbatas. Pengukuran pada perangkat tersebut menunjukkan model resolusi 960 hanya mencapai 1,26 *frame* per detik, dibandingkan 3,01 *frame* per detik untuk model resolusi 640. Resolusi yang dinaikkan memperlambat inferensi sekitar 58% pada perangkat target. Pembahasan menyeluruh mengenai kecepatan seluruh varian pada perangkat penerapan dan implikasinya terhadap pengertian waktu nyata disajikan pada Bab IV.

Berdasarkan keseluruhan hasil ini, penyetelan dinilai cukup pada tahap ini dan tidak dilanjutkan dengan *hyperparameter* lain. Penyetelan resolusi tunggal sudah memberikan perbaikan yang konsisten pada seluruh metrik, dengan peningkatan terbesar justru pada kelas yang paling lemah, sesuai dasar teoretis yang diajukan di awal. Memperluas penyetelan ke varian lain atau ke *hyperparameter* tambahan akan keluar dari lingkup optimasi terhadap satu model terpilih dan berisiko menurunkan keterkendalian atribusi hasil. Pilihan konfigurasi akhir yang diterapkan pada sistem, antara model resolusi 640 yang lebih cepat dan model resolusi 960 yang lebih akurat, ditentukan berdasarkan pertimbangan kecepatan pada perangkat target yang dibahas pada Bab IV.

3.9 Perancangan dan Implementasi Sistem

Model hasil pelatihan dan penyetelan diterapkan pada sebuah sistem pemantauan berbasis web yang mengolah aliran CCTV kawasan Malioboro secara langsung. Subbab ini menjelaskan arsitektur sistem, mekanisme penanganan aliran video dan penjadwalan inferensi, estimasi kepadatan beserta ambang notifikasi, dan visualisasi kepadatan pada antarmuka.

3.9.1 Arsitektur Sistem

Sistem terdiri atas dua bagian utama, yaitu *backend* dan *frontend*. Bagian *backend* dibangun menggunakan kerangka kerja FastAPI dengan bahasa Python, dan bertanggung jawab atas pengambilan aliran CCTV, penjalanan inferensi model, penyimpanan riwayat deteksi, serta pengiriman hasil ke antarmuka. Bagian *frontend* dibangun menggunakan pustaka React dengan *Vite* dan *Tailwind*, dan menampilkan video langsung beserta hasil deteksi, grafik kepadatan, dan panel notifikasi kepada pengguna.

Sumber data sistem adalah 22 kamera CCTV publik yang disediakan melalui laman

resmi pemerintah Kota Yogyakarta dalam format aliran HLS. Registri kamera, termasuk tautan aliran dan konfigurasi ambang tiap kamera, disimpan dalam berkas konfigurasi. Riwayat deteksi disimpan dalam basis data SQLite yang dibuat otomatis saat sistem dijalankan, dan digunakan sebagai sumber data grafik kepadatan. Hasil deteksi terbaru dikirim ke antarmuka melalui mekanisme *WebSocket* agar tampilan dapat diperbarui tanpa pemuatan ulang halaman.

3.9.2 Penanganan Aliran CCTV dan Penjadwalan Inferensi

Menjalankan inferensi secara terus-menerus pada 22 aliran sekaligus tidak memungkinkan pada perangkat dengan satu GPU terbatas, sebagaimana ditunjukkan oleh hasil kecepatan pada Bab IV. Oleh karena itu, sistem membedakan penanganan antara kamera yang sedang dipilih pengguna dan kamera lainnya melalui dua mekanisme terpisah.

Kamera yang sedang dipilih ditangani oleh pemroses kamera aktif yang menjalankan dua utas, yaitu satu utas untuk membaca aliran video dan satu utas untuk menjalankan inferensi pada interval tetap. Pemisahan ini bertujuan menjaga agar tampilan video tetap mulus sementara inferensi berjalan pada laju yang lebih lambat. Hasil deteksi ditampilkan dengan teknik *Motion JPEG* (MJPEG), yang memungkinkan sistem mengatur interval inferensi secara mandiri dan menampilkan kotak deteksi bersamaan dengan *frame* terbaru. Tanpa pemisahan ini, kotak deteksi akan tampak tertinggal dari *frame* yang sedang ditampilkan karena laju inferensi yang jauh lebih rendah daripada laju video.

Kamera yang tidak sedang dipilih ditangani oleh kumpulan penjadwal latar belakang yang menggilir kamera satu per satu secara berurutan dalam satu utas. Pada tiap giliran, sistem membuka aliran satu kamera, mengambil satu *frame*, menjalankan inferensi, lalu menutup aliran tersebut dan melanjutkan ke kamera berikutnya. Interval antar giliran dihitung agar tiap kamera mendapat giliran kira-kira sekali per 60 detik, dengan membagi jendela waktu 60 detik dengan jumlah kamera nonaktif. Mekanisme ini menjaga agar seluruh kamera tetap terpantau untuk keperluan deteksi anomali kepadatan, tanpa membebani GPU dengan 22 inferensi serentak.

Pengukuran pada kondisi jaringan kampus menunjukkan rata-rata waktu satu siklus pemrosesan latar belakang per kamera sekitar 2,59 detik, sehingga satu putaran penuh untuk 21 kamera nonaktif memakan waktu sekitar 54,3 detik, mendekati target rancangan 60 detik. Pengukuran ini dilakukan pada jaringan dengan kecepatan unduh 123 Mbps dan *ping* 4 milidetik ke server, sehingga durasi nyata pada kondisi jaringan lain dapat berbeda.

Pengujian pada kondisi nyata menemukan bahwa sebagian kamera publik dapat tidak aktif sewaktu-waktu. Pada implementasi awal, pembaca aliran dirancang untuk mencoba menyambung ulang tanpa batas, sehingga satu kamera yang tidak aktif membuat satu siklus pemrosesan tertahan hingga 154 detik. Karena penjadwal latar

belakang berjalan berurutan dalam satu utas, penundaan ini menghentikan pemantauan seluruh kamera lain selama itu. Masalah ini diatasi dengan menambahkan batas waktu pengambilan *frame* sebesar 10 detik. Jika pengambilan melewati batas tersebut, proses dihentikan secara kooperatif dan giliran dilanjutkan ke kamera berikutnya, dengan status dicatat sebagai *timeout*. Setelah perbaikan, satu kamera yang tidak aktif hanya menambah sekitar 10 detik pada satu putaran, turun dari 154 detik sebelumnya, sehingga dampak satu kamera mati terhadap durasi satu putaran berkurang dari lebih dari 285% menjadi sekitar 14%.

3.9.3 Estimasi Kepadatan dan Ambang Notifikasi

Notifikasi kepadatan didasarkan pada konsep *Level of Service* (LOS) pejalan kaki, yang menyatakan tingkat kenyamanan suatu ruang pejalan kaki berdasarkan kepadatan orang per satuan luas [10]. Standar serupa juga diatur dalam pedoman teknis penyediaan prasarana pejalan kaki di Indonesia [11]. Penerapan LOS menuntut konversi dari jumlah orang yang terdeteksi pada citra menjadi kepadatan pada luas ruang nyata, yang dilakukan melalui transformasi homografi. Titik acuan dan jarak nyata di lapangan diperkirakan menggunakan *Google Earth*.

Transformasi homografi mensyaratkan sudut pandang kamera yang tetap, karena pemetaan antara bidang citra dan bidang nyata bergantung pada posisi kamera yang konsisten. Pada kenyataannya, sebagian kamera CCTV di kawasan ini memiliki sudut pandang yang tidak tetap, sebagian di antaranya dapat digerakkan, sebagaimana ditunjukkan pada Gambar 3.3 yang memperlihatkan kamera yang sama pada sudut yang berbeda. Oleh karena itu, kalibrasi LOS melalui homografi hanya diterapkan pada dua kamera yang sudut pandangnya relatif tetap sebagai contoh penerapan, sedangkan ambang untuk kamera lain ditentukan secara manual. Pembatasan ini sejalan dengan batasan penelitian yang diuraikan pada Bab I.



Gambar 3.3. Kamera CCTV yang sama pada dua sudut pandang berbeda

Alasan yang sama mendasari keputusan untuk tidak menggunakan area pemantauan terbatas (*Region of Interest*). Poligon area yang digambar satu kali tidak lagi sah setelah

kamera bergeser, sehingga penghitungan objek dilakukan pada seluruh *frame*, bukan pada area terbatas tertentu.

Ambang notifikasi ditetapkan per kelas untuk tiap kamera, bukan sebagai satu ambang tunggal yang berlaku sama untuk seluruh kamera. Hal ini diperlukan karena tiap titik kamera mewakili ruang dengan kapasitas yang berbeda, sehingga jumlah objek yang menandakan kepadatan berlebih pun berbeda antar lokasi. Untuk dua kamera yang terkalibrasi LOS, ambang jumlah orang diturunkan dari kapasitas ruang hasil homografi. Untuk kamera lainnya, ambang ditentukan secara manual. Nilai ambang ini disimpan dalam berkas konfigurasi tiap kamera.

Agar notifikasi tidak terkirim berulang kali selama kondisi padat masih berlangsung, sistem menerapkan tenggang waktu antar notifikasi untuk kombinasi kamera dan jenis notifikasi yang sama. Tenggang waktu ditetapkan selama 7 menit, yang dinilai cukup untuk mencegah notifikasi yang berlebihan tanpa membuat sistem lambat menanggapi kondisi yang dapat berubah cepat. Jika kepadatan melonjak jauh melampaui ambang, tenggang waktu ini diabaikan agar kondisi yang lebih berbahaya tetap diberitahukan. Penetapan nilai tenggang waktu ini adalah pertimbangan rekayasa, bukan mengikuti standar tertentu.

3.9.4 Visualisasi Kepadatan pada Dashboard

Antarmuka menyajikan grafik kepadatan yang merangkum riwayat deteksi tiap kamera. Metrik utama yang ditampilkan adalah jumlah orang, bukan gabungan seluruh kelas objek, karena penggabungan orang dan kendaraan menjadi satu angka akan kehilangan makna mengingat skala kepadatan keduanya berbeda. Selain itu, dasar notifikasi penelitian ini adalah LOS pejalan kaki yang khusus berlaku untuk orang. Jumlah objek kelas kendaraan tetap dapat dilihat secara terpisah melalui pilihan kelas pada antarmuka, tidak digabung dengan jumlah orang.

Data ditampilkan dengan agregasi per jam. Penyajian tren per jam digunakan sebagai representasi standar pada pemantauan kerumunan, sebagaimana ditunjukkan pada platform pemantauan transit yang menampilkan variasi jumlah orang per jam sepanjang hari [14]. Visualisasi semacam ini membantu operator memahami kondisi kepadatan tanpa harus mengamati seluruh kamera secara manual, yang melelahkan dan rawan kesalahan [15]. Tiap jam diwakili oleh dua nilai, yaitu rata-rata sebagai gambaran kondisi tipikal dan nilai puncak sebagai penanda lonjakan sesaat, karena untuk tujuan keselamatan momen puncak kepadatan lebih penting daripada rata-rata yang dapat menutupi lonjakan singkat.

Pengguna dapat memilih dua rentang waktu. Rentang harian menampilkan tren per jam dalam satu hari berjalan, sedangkan rentang mingguan menampilkan tren per hari selama tujuh hari terakhir untuk memperlihatkan pola perbedaan antar hari. Grafik

disajikan terpisah untuk tiap kamera, karena tiap lokasi memiliki karakter kepadatan yang berbeda. Data untuk kedua rentang ini diambil dari riwayat deteksi yang tersimpan dalam basis data.

BAB IV

HASIL DAN PEMBAHASAN

Berikut ini adalah yang perlu diperhatikan untuk mengisi bab hasil dan pembahasan:

1. Setiap rumusan masalah boleh memiliki lebih dari 1 tujuan.
2. Setiap subbab harus spesifik menjawab setiap tujuan yang dituliskan.
3. Setiap rumusan masalah boleh dijawab dengan 1 subbab atau lebih.

Berikut ini adalah contoh sub bab untuk menjelaskan tujuan penelitian.

4.1 Pembahasan Tujuan 1 dengan Hasil Penelitian 1 (Ubah Judul Sesuai dengan Hal yang Hendak dibahas)

Sub bab pertama adalah membahas tujuan penelitian pertama dengan hasil penelitian ke-1. Dapat ditambahkan beberapa sub bab jika diperlukan.

4.2 Pembahasan Tujuan 1 dengan Hasil Penelitian 2 (Ubah Judul Sesuai dengan Hal yang Hendak dibahas)

Sub bab kedua adalah membahas tujuan penelitian pertama dengan hasil penelitian ke-2. Sub bab ini merupakan contoh tambahan sub bab pertama.

4.3 Pembahasan Tujuan 2 dengan Hasil Penelitian 3 (Ubah Judul Sesuai dengan Hal yang Hendak dibahas)

Sub bab ketiga adalah membahas tujuan penelitian kedua. Dapat ditambahkan beberapa sub bab jika diperlukan.

4.4 Perbandingan Hasil Penelitian dengan Hasil Terdahulu

Pembahasan penutup dapat menjelaskan mengenai kelebihan hasil pengembangan / penelitian dan kekurangan dibandingkan dengan skripsi atau penelitian terdahulu atau perbandingan terhadap produk lain yang ada di pasaran. Penulis dapat menggunakan tabel untuk membandingkan secara gamblang dan menjelaskannya.

BAB V

TAMBAHAN (OPSIONAL)

Anda boleh menambahkan Bab jika diperlukan. Jumlah Bab tidak harus sesuai dengan *template*.

Bab tambahan ini diperlukan jika hasil penelitian untuk menjawab tujuan cukup panjang atau terdiri dari banyak sub bab. Mahasiswa boleh menjawab 1 tujuan penelitian dengan 1 bab.

BAB VI

KESIMPULAN DAN SARAN

6.1 Kesimpulan

Kesimpulan dapat diawali dengan apa yang dilakukan dengan tugas akhir ini lalu dilanjutkan dengan poin-poin yang menjawab tujuan penelitian, apakah tujuan sudah tercapai atau belum, tentunya berdasarkan data ataupun hasil dari Bab pembahasan sebelumnya. Dalam beberapa hal, kesimpulan dapat juga berisi tentang temuan/*findings* yang Anda dapatkan setelah melakukan pengamatan dan atau analisis terhadap hasil penelitian.

Kesimpulan menjawab seberapa jauh rumusan masalah tercapai berdasarkan hasil penelitian. Semua rumusan masalah harus disimpulkan berdasarkan data penelitian.

6.2 Saran

Saran berisi hal-hal yang bisa dilanjutkan dari penelitian atau skripsi ini, yang belum dilakukan karena batasan permasalahan. Saran bukan berisi saran kepada sistem atau pengguna, tetapi saran diberikan kepada aspek penelitian yang dapat dikembangkan dan ditambahkan di penelitian atau skripsi selanjutnya.

Catatan: Mahasiswa perlu melihat sinkronisasi antara rumusan masalah, tujuan, metode, hasil penelitian, dan kesimpulan.

DAFTAR PUSTAKA

- [1] H. N. Rahmah, M. J. Rahayu, and E. F. Rini, “Tingkat pelayanan jalur pedestrian di kawasan wisata Malioboro, Kota Yogyakarta,” *Desa-Kota: Jurnal Perencanaan Wilayah, Kota, dan Permukiman*, vol. 7, no. 2, pp. 102–111, 2025.
- [2] Pemerintah Kota Yogyakarta, “Jumlah pengunjung wisata menurut jenis pengunjung di Kota Yogyakarta tahun 2024,” Portal Satu Data Indonesia, 2024, [Daring]. Tersedia: <http://data.go.id/dataset/dataset/kyda2024-99>.
- [3] Badan Pusat Statistik Provinsi D.I. Yogyakarta, “Jumlah kunjungan wisatawan nusantara menurut tujuan (perjalanan) tahun 2025,” BPS Provinsi D.I. Yogyakarta, 2025, [Daring]. Tersedia: <https://yogyakarta.bps.go.id/id/statistics-table/2/NTE0IzI=/jumlah-kunjungan-wisatawan-nusantara->
- [4] A. M. S. Lagalo and D. Talib, “Dinamika aktivitas pariwisata di kawasan Malioboro Yogyakarta saat mudik Lebaran: Studi wisata urban,” *Tulisan Ilmiah Pariwisata (TULIP)*, vol. 7, no. 2, pp. 144–148, 2024.
- [5] A. M. Saputra and Y. D. Artini, “Pengelolaan lalu lintas di kawasan Malioboro,” *Paradigma: Jurnal Ilmu Administrasi*, vol. 10, no. 2, pp. 136–153, 2021.
- [6] A. Khan, J. A. Shah, K. Kadir, W. Albattah, and F. Khan, “Crowd monitoring and localization using deep convolutional neural network: A review,” *Applied Sciences*, vol. 10, no. 14, p. 4781, 2020.
- [7] F. Caprotti and D. Liu, “Platform urbanism and the Chinese smart city: The co-production and territorialisation of Hangzhou City Brain,” *GeoJournal*, vol. 87, pp. 1559–1573, 2022.
- [8] S. L. B. Ginting, H. Maulana, R. A. Priatna, D. D. Fauzzan, and D. Setiawan, “Crowd detection using YOLOv3-Tiny method and Viola-Jones algorithm at mall,” *International Journal of Informatics, Information System and Computer Engineering*, vol. 2, no. 1, pp. 13–22, 2021.
- [9] A. Sharma, C. Mhatre, S. Gawali, R. Bokkasam, B. Sharma, V. Pattanaik, P. Rathore, R. Krishnapuram, V. G. Kovvali, A. Chakraborty, and Y. Simmhan, “BMD-45: A large-scale CCTV vehicle detection dataset for urban traffic in developing cities,” in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR) Findings*, 2026.
- [10] J. J. Fruin, “Designing for pedestrians: A level-of-service concept,” *Highway Research Record*, no. 355, pp. 1–15, 1971.
- [11] Kementerian Pekerjaan Umum dan Perumahan Rakyat, “Pedoman perencanaan, penyediaan, dan pemanfaatan prasarana dan sarana jaringan pejalan kaki di kawasan perkotaan,” Peraturan Menteri PUPR No. 03/PRT/M/2014, 2014.
- [12] M. Ş. Gündüz and G. Işık, “A new YOLO-based method for real-time crowd detection from video and performance analysis of YOLO models,” *Journal of Real-Time Image Processing*, vol. 20, no. 1, p. 5, 2023.

- [13] W. T. D. T. Hansika, M. A. P. Madhawa, N. T. M. Sajith, M. N. M. Aashiq, and M. N. A. Hinas, "Privacy-preserving real-time crowd counting on IoT enabled edge devices using YOLOv8n and Norfair," in *Proc. IEEE Int. Research Conf. Smart Computing and Systems Engineering (SCSE)*. Kelaniya, Sri Lanka: IEEE, 2026.
- [14] S. Apeksha, M. Sohan, N. H. Gowda, R. Ramya, and M. Jadhav, "AI-transit alerts: A smart platform for tracking the number of people using public transportation in real time," in *Proc. 2nd Int. Conf. Computing for Sustainability and Intelligent Future (COMP-SIF)*. Bengaluru, India: IEEE, 2026.
- [15] V. W. H. Wong and K. H. Law, "Fusion of CCTV video and spatial information for automated crowd congestion monitoring in public urban spaces," *Algorithms*, vol. 16, no. 3, p. 154, 2023.
- [16] Y. Zhang, Z. Guo, J. Wu, Y. Tian, H. Tang, and X. Guo, "Real-time vehicle detection based on improved YOLO v5," *Sustainability*, vol. 14, no. 19, p. 12274, 2022.
- [17] K. Oksuz, B. C. Cam, S. Kalkan, and E. Akbas, "Imbalance problems in object detection: A review," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 43, no. 10, pp. 3388–3415, 2021.
- [18] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards real-time object detection with region proposal networks," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 6, pp. 1137–1149, 2017.
- [19] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788.
- [20] T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan, and S. Belongie, "Feature pyramid networks for object detection," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2117–2125.
- [21] J. R. Terven, D.-M. Córdova-Esparza, and J.-A. Romero-González, "A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS," *Machine Learning and Knowledge Extraction*, vol. 5, no. 4, pp. 1680–1716, 2023.
- [22] R. Khanam and M. Hussain, "YOLO11: An overview of the key architectural enhancements," arXiv preprint arXiv:2410.17725, 2024.
- [23] Y. Zhao, W. Lv, S. Xu, J. Wei, Q. Dang, Y. Liu, and J. Chen, "DETRs beat YOLOs on real-time object detection," in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, 2024, pp. 16 965–16 974.
- [24] R. Padilla, S. L. Netto, and E. A. B. da Silva, "A survey on performance metrics for object-detection algorithms," in *Proc. International Conf. Systems, Signals and Image Processing (IWSSIP)*, 2020, pp. 237–242.
- [25] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, "Microsoft COCO: Common objects in context," in *Proc. European Conf. Computer Vision (ECCV)*, 2014, pp. 740–755.

- [26] S. Tenckhoff, M. Koddenbrock, and E. Rodner, “Feedback-driven object detection and iterative model improvement for accurate annotations,” arXiv preprint arXiv:2411.19835, 2025.
- [27] N. Carion, L. Gustafson, Y.-T. Hu *et al.*, “SAM 3: Segment anything with concepts,” arXiv preprint arXiv:2511.16719, 2025.
- [28] Z. Luo *et al.*, “MIO-TCD: A new benchmark dataset for vehicle classification and localization,” *IEEE Transactions on Image Processing*, vol. 27, no. 10, pp. 5129–5141, 2018.

Catatan: Daftar pustaka adalah apa yang dirujuk atau disitasi, bukan apa yang telah dibaca, jika tidak ada dalam sitasi maka tidak perlu dituliskan dalam daftar pustaka.

LAMPIRAN

L.1 Isi Lampiran

Lampiran bersifat opsional bergantung hasil kesepakatan dengan pembimbing dapat berupa:

1. Bukti pelaksanaan Kuesioner seperti pertanyaan kuesioner, resume jawaban responden, dan dokumentasi kuesioner.
2. Spesifikasi Aplikasi atau Sistem yang dikembangkan meliputi spesifikasi teknis aplikasi, tautan unduh aplikasi, manual penggunaan aplikasi, hingga screenshot aplikasi.
3. Cuplikan kode yang sekiranya penting dan ditambahkan.
4. Tabel yang terlalu panjang yang masih diperlukan tetapi tidak memungkinkan untuk ditayangkan di bagian utama skripsi.
5. Gambar-gambar pendukung yang tidak terlalu penting untuk ditampilkan di bagian utama. Akan tetapi, mendukung argumentasi/pengamatan/analisis.
6. Penurunan rumus-rumus atau pembuktian suatu teorema yang terlalu panjang dan terlalu teknis sehingga Anda berasumsi bahwa pembaca biasa tidak akan menelaah lebih lanjut. Hal ini digunakan untuk memberikan kesempatan bagi pembaca tingkat lanjut untuk melihat proses penurunan rumus-rumus ini.

LAMPIRAN


L.2 Panduan Latex

L.2.1 Syntax Dasar

L.2.1.1 Penggunaan Sitasi

Contoh penggunaan sitasi [?, ?] [?] [?] [?] [?, ?]

L.2.1.2 Penulisan Gambar



Gambar L.1. Contoh gambar.

Contoh gambar terlihat pada Gambar L.1. Gambar diambil dari [?].

L.2.1.3 Penulisan Tabel

Tabel L.1. Tabel ini

ID	Tinggi Badan (cm)	Berat Badan (kg)
A23	173	62
A25	185	78
A10	162	70

Contoh penulisan tabel bisa dilihat pada Tabel L.1.

L.2.1.4 Penulisan formula

Contoh penulisan formula

$$L_{\psi_z} = \{t_i \mid v_z(t_i) \leq \psi_z\} \quad (1)$$

Contoh penulisan secara *inline*: $PV = nRT$. Untuk kasus-kasus tertentu, kita membutuhkan perintah "mathit" dalam penulisan formula untuk menghindari adanya jeda saat penulisan formula.

Contoh formula **tanpa** menggunakan "mathit": $PVA = RTD$

Contoh formula **dengan** menggunakan "mathit": $PVA = RTD$

L.2.1.5 Contoh list

Berikut contoh penggunaan list

1. First item
2. Second item
3. Third item

L.2.2 Blok Beda Halaman

L.2.2.1 Membuat algoritma terpisah

Untuk membuat algoritma terpisah seperti pada contoh berikut, kita dapat memanfaatkan perintah *algstore* dan *algrestore* yang terdapat pada paket *algcompatible*. Pada dasarnya, kita membuat dua blok algoritma dimana blok pertama kita simpan menggunakan *algstore* dan kemudian di-restore menggunakan *algrestore* pada algoritma kedua. Perintah tersebut dimaksudkan agar terdapat kesinamungan antara kedua blok yang sejatinya adalah satu blok.

Algorithm 1 Contoh algoritma

```
1: procedure CREATESET( $v$ )  
2:   Create new set containing  $v$   
3: end procedure
```

Pada blok algoritma kedua, tidak perlu ditambahkan caption dan label, karena sudah menjadi satu bagian dalam blok pertama. Pembagian algoritma menjadi dua bagian ini berguna jika kita ingin menjelaskan bagian-bagian dari sebuah algoritma, maupun untuk memisah algoritma panjang dalam beberapa halaman.

```
4: procedure CONCATSET( $v$ )  
5:   Create new set containing  $v$   
6: end procedure
```

L.2.2.2 Membuat tabel terpisah

Untuk membuat tabel panjang yang melebihi satu halaman, kita dapat mengganti kombinasi *table* + *tabular* menjadi *longtable* dengan contoh sebagai berikut.

Tabel L.2. Contoh tabel panjang

header 1	header 2
foo	bar
foo	bar
foo	bar
foo	bar
foo	bar
foo	bar
foo	bar
foo	bar
foo	bar
foo	bar
foo	bar

L.2.2.3 Menulis formula terpisah halaman

Terkadang kita butuh untuk menuliskan rangkaian formula dalam jumlah besar sehingga melewati batas satu halaman. Solusi yang digunakan bisa saja dengan memindahkan satu blok formula tersebut pada halaman yang baru atau memisah rangkaian formula menjadi dua bagian untuk masing-masing halaman. Cara yang pertama mungkin akan menghasilkan alur yang berbeda karena ruang kosong pada halaman pertama akan diisi oleh teks selanjutnya. Sehingga di sini kita dapat memanfaatkan *align* yang sudah diatur dengan mode *allowdisplaybreaks*. Penggunaan *align* ini memungkinkan satu rangkaian formula terpisah berbeda halaman.

Contoh sederhana dapat digambarkan sebagai berikut.

$$\begin{aligned}
 x &= y^2 \\
 x &= y^3 \\
 a + b &= c \\
 x &= y - 2 \\
 a + b &= d + e \\
 x^2 + 3 &= y \\
 a(x) &= 2x
 \end{aligned}
 \tag{2}$$

$$b_i = 5x$$

$$10x^2 = 9x$$

$$2x^2 + 3x + 2 = 0$$

$$5x - 2 = 0$$

$$d = \log x$$

$$y = \sin x$$

LAMPIRAN

L.3 Format Penulisan Referensi

Penulisan referensi mengikuti aturan standar yang sudah ditentukan. Untuk internasionalisasi DTETI, maka penulisan referensi akan mengikuti standar yang ditetapkan oleh IEEE (*International Electronics and Electrical Engineers*). Aturan penulisan ini bisa diunduh di <http://www.ieee.org/documents/ieeecitationref.pdf>. Gunakan Mendeley sebagai *reference manager* dan *export* data ke format Bibtex untuk digunakan di Latex.

Berikut ini adalah sampel penulisan dalam format IEEE:

L.3.1 Book

Basic Format:

- [1] J. K. Author, "Title of chapter in the book," in Title of His Published Book, xth ed. City of Publisher, Country: Abbrev. of Publisher, year, ch. x, sec. x, pp. xxx-xxx.

Examples:

- [1] B. Klaus and P. Horn, Robot Vision. Cambridge, MA: MIT Press, 1986.
- [2] L. Stein, "Random patterns," in Computers and You, J. S. Brake, Ed. New York: Wiley, 1994, pp. 55-70.
- [3] R. L. Myer, "Parametric oscillators and nonlinear materials," in Nonlinear Optics, vol. 4, P. G. Harper and B. S. Wherret, Eds. San Francisco, CA: Academic, 1977, pp. 47-160.
- [4] M. Abramowitz and I. A. Stegun, Eds., Handbook of Mathematical Functions (Applied Mathematics Series 55). Washington, DC: NBS, 1964, pp. 32-33.
- [5] E. F. Moore, "Gedanken-experiments on sequential machines," in Automata Studies (Ann. of Mathematical Studies, no. 1), C. E. Shannon and J. McCarthy, Eds. Princeton, NJ: Princeton Univ. Press, 1965, pp. 129-153.
- [6] Westinghouse Electric Corporation (Staff of Technology and Science, Aerospace Div.), Integrated Electronic Systems. Englewood Cliffs, NJ: Prentice-Hall, 1970.
- [7] M. Gorkii, "Optimal design," Dokl. Akad. Nauk SSSR, vol. 12, pp. 111-122, 1961 (Transl.: in L. Pontryagin, Ed., The Mathematical Theory of Optimal Processes. New York: Interscience, 1962, ch. 2, sec. 3, pp. 127-135).

- [8] G. O. Young, "Synthetic structure of industrial plastics," in *Plastics*, vol. 3, *Polymers of Hexadromicon*, J. Peters, Ed., 2nd ed. New York: McGraw-Hill, 1964, pp. 15-64.

L.3.2 Handbook

Basic Format:

- [1] Name of Manual/Handbook, x ed., Abbrev. Name of Co., City of Co., Abbrev. State, year, pp. xx-xx.

Examples:

- [1] Transmission Systems for Communications, 3rd ed., Western Electric Co., Winston Salem, NC, 1985, pp. 44-60.
- [2] Motorola Semiconductor Data Manual, Motorola Semiconductor Products Inc., Phoenix, AZ, 1989.
- [3] RCA Receiving Tube Manual, Radio Corp. of America, Electronic Components and Devices, Harrison, NJ, Tech. Ser. RC-23, 1992.

Conference/Prosiding

Basic Format:

- [1] J. K. Author, "Title of paper," in Unabbreviated Name of Conf., City of Conf., Abbrev. State (if given), year, pp.xxx-xxx.

Examples:

- [1] J. K. Author [two authors: J. K. Author and A. N. Writer] [three or more authors: J. K. Author et al.], "Title of Article," in [Title of Conf. Record as], [copyright year] © [IEEE or applicable copyright holder of the Conference Record]. doi: [DOI number]

Sumber Online/Internet

Basic Format:

- [1] J. K. Author. (year, month day). Title (edition) [Type of medium]. Available: [http://www.\(URL\)](http://www.(URL))

Examples:

- [1] J. Jones. (1991, May 10). Networks (2nd ed.) [Online]. Available: <http://www.atm.com>

Skripsi, Tesis dan Disertasi

Basic Format:

- [1] J. K. Author, "Title of thesis," M.S. thesis, Abbrev. Dept., Abbrev. Univ., City of Univ., Abbrev. State, year.

[2] J. K. Author, "Title of dissertation," Ph.D. dissertation, Abbrev. Dept., Abbrev. Univ., City of Univ., Abbrev. State, year.

Examples:

[1] J. O. Williams, "Narrow-band analyzer," Ph.D. dissertation, Dept. Elect. Eng., Harvard Univ., Cambridge, MA, 1993. [2] N. Kawasaki, "Parametric study of thermal and chemical nonequilibrium nozzle flow," M.S. thesis, Dept. Electron. Eng., Osaka Univ., Osaka, Japan, 1993

LAMPIRAN

L.4 Contoh Source Code

L.4.1 Sample algorithm

Algorithm 2 Kruskal's Algorithm

```
1: procedure MAKESET( $v$ )
2:   Create new set containing  $v$ 
3: end procedure
4:
5: function FINDSET( $v$ )
6:   return a set containing  $v$ 
7: end function
8:
9: procedure UNION( $u, v$ )
10:  Unites the set that contain  $u$  and  $v$  into a new set
11: end procedure
12:
13: function KRUSKAL( $V, E, w$ )
14:   $A \leftarrow \{\}$ 
15:  for each vertex  $v$  in  $V$  do
16:    MakeSet( $v$ )
17:  end for
18:  Arrange  $E$  in increasing costs, ordered by  $w$ 
19:  for each  $(u, v)$  taken from the sorted list do
20:    if FindSet( $u$ )  $\neq$  FindSet( $v$ ) then
21:       $A \leftarrow A \cup \{(u, v)\}$ 
22:      Union( $u, v$ )
23:    end if
24:  end for
25:  return  $A$ 
26: end function
```

L.4.2 Sample Python code

```
1 import numpy as np
2
3 def incmatrix (genl1 , genl2):
4     m = len (genl1)
5     n = len (genl2)
6     M = None #to become the incidence matrix
7     VT = np.zeros ((n*m,1) , int) #dummy variable
8
9     #compute the bitwise xor matrix
10    M1 = bitxormatrix (genl1)
11    M2 = np.triu (bitxormatrix (genl2) ,1)
12
13    for i in range (m-1):
14        for j in range (i+1, m):
15            [r,c] = np.where (M2 == M1[i,j])
16            for k in range (len (r)):
17                VT[(i)*n + r[k]] = 1;
18                VT[(i)*n + c[k]] = 1;
19                VT[(j)*n + r[k]] = 1;
20                VT[(j)*n + c[k]] = 1;
21
22    if M is None:
23        M = np.copy (VT)
24    else:
25        M = np.concatenate ((M, VT) , 1)
26
27    VT = np.zeros ((n*m,1) , int)
28
29    return M
```

L.4.3 Sample Matlab code

```
1 function X = BitXorMatrix(A,B)
2 %function to compute the sum without charge of two vectors
3
4 %convert elements into unsigned integers
5 A = uint8(A);
6 B = uint8(B);
7
8 m1 = length(A);
9 m2 = length(B);
10 X = uint8(zeros(m1, m2));
11 for n1=1:m1
12     for n2=1:m2
13         X(n1, n2) = bitxor(A(n1), B(n2));
14     end
15 end
```